

Алгоритмы и структуры данных

Косяков Михаил Сергеевич
к.т.н., доцент кафедры ВТ

Принцип divide-and-conquer

- Решаем задачу рекурсивно, применяя на каждом уровне рекурсии три шага:
- **Divide:** разделяем задачу на несколько таких же задач меньшего размера
- **Conquer:** решаем подзадачи рекурсивно
 - Подзадачи малого размера решаем прямым решением
- **Combine:** комбинируем решения подзадач в решение исходной задачи

Оценка сложности

- $T(N) = T(N/2) + T(N/2) + 1$, где $T(N)$ – время выполнения задачи размера N
- Какая сложность?

Оценка сложности

- $T(N) = T(N/2) + T(N/2) + 1$, где $T(N)$ – время выполнения задачи размера N
- Метод №1 – сделаем предположение и докажем его корректность
- По индукции: $T(N) \leq cN$ для некоторой константы c
 - Более строгое предположение: $T(N) \leq cN - a$, $a \geq 1$
 - База индукции: $T(1) \leq c - a$
 - Шаг индукции: пусть $T(N/2) \leq cN/2 - a$, надо показать, что $T(N) \leq cN - a$
 - $T(N) = T(N/2) + T(N/2) + 1 \leq cN/2 - a + 1 \leq cN - a$, $a \geq 1$
- Как угадать решение?



Оценка сложности

- $T(N) = T(N/2) + T(N/2) + 1$, где $T(N)$ – время выполнения задачи размера N
- Метод №1 – сделаем предположение и докажем его корректность
- По индукции: $T(N) \leq cN$ для некоторой константы c
 - Более строгое предположение: $T(N) \leq cN - a$, $a \geq 1$
 - База индукции: $T(1) \leq c - a$
 - Шаг индукции: пусть $T(N/2) \leq cN/2 - a$, надо показать, что $T(N) \leq cN - a$
 - $T(N) = T(N/2) + T(N/2) + 1 \leq cN/2 - a + 1 \leq cN - a$, $a \geq 1$
- Метод №2 – построим дерево рекурсии



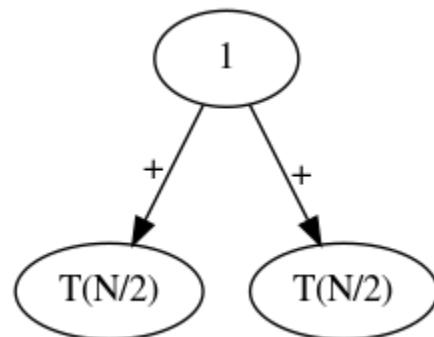
Дерево рекурсии

- $T(N) = T(N/2) + T(N/2) + 1$



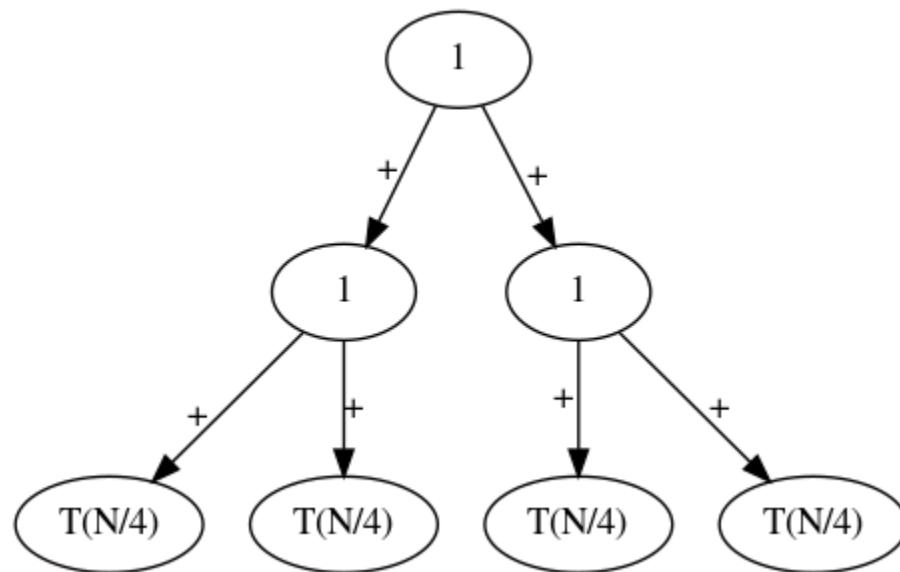
Дерево рекурсии

- $T(N/2) = T(N/4) + T(N/4) + 1$



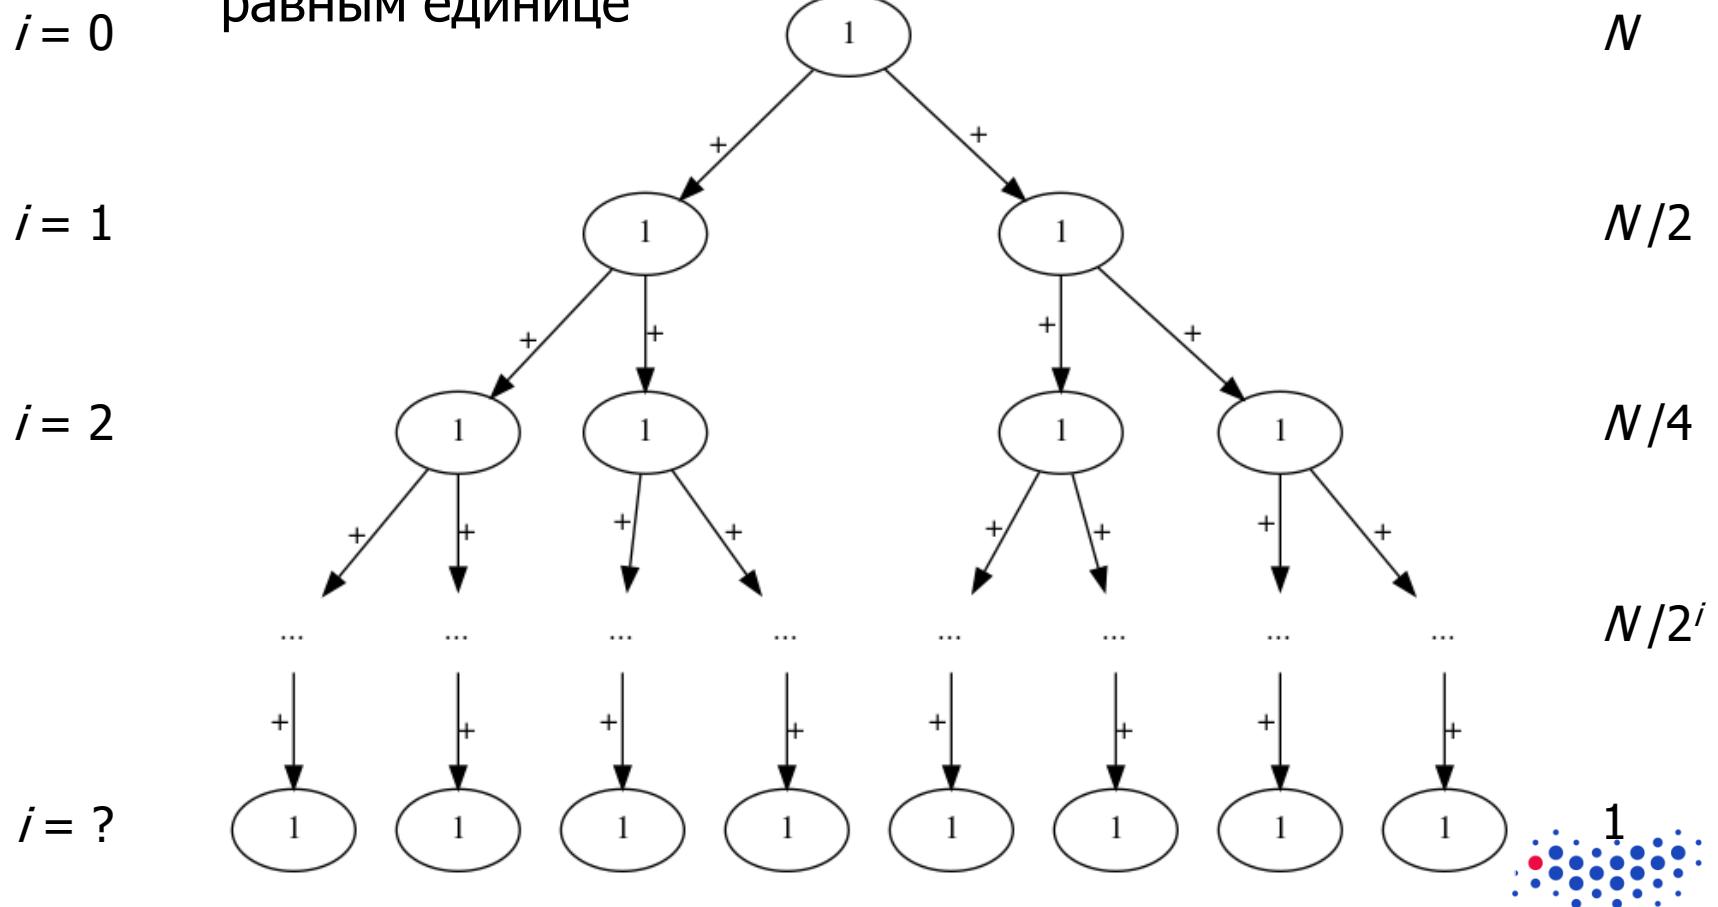
Дерево рекурсии

- $T(N/4) = T(N/8) + T(N/8) + 1$



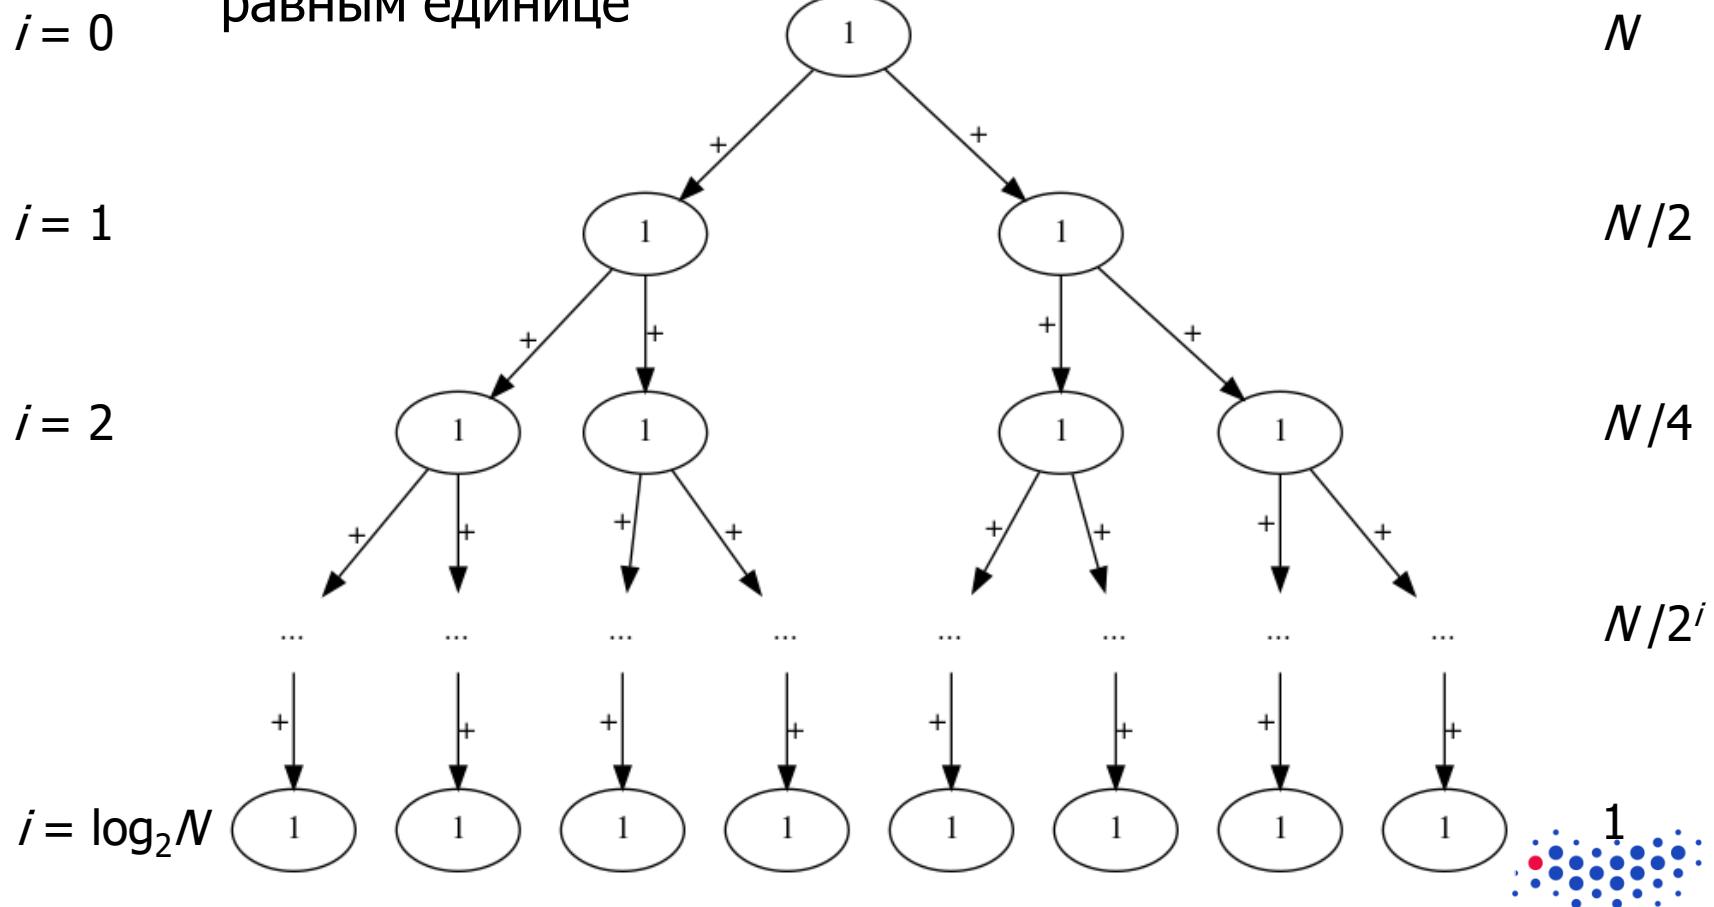
Дерево рекурсии

- Рекурсия останавливается, когда размер подзадачи станет равным единице



Дерево рекурсии

- Рекурсия останавливается, когда размер подзадачи станет равным единице



Оценка сложности

- На нижнем уровне N узлов (подзадач) каждая со временем выполнения $T(1)$, поэтому время работы этого уровня $\Theta(N)$
- Общее время работы:

$$\begin{aligned}1 + 2^1 + 2^2 + \dots + 2^{\log N - 1} + \Theta(N) &= \\&= (2^{\log N} - 1) / (2 - 1) + \Theta(N) = N - 1 + \Theta(N)\end{aligned}$$

- $T(N) = \Theta(N)$
- Предположение: количество элементов в исходной задаче равно степени двойки
 - Не влияет на порядок роста: почему?



Умножение чисел

- Требуется перемножить два n -значных числа
- В столбик? Оценка сложности: $\Theta(N^2)$
- Divide: разобьем каждое число на две $n/2$ -значные половины
 - $\text{num}_1 = x_1 * 10^{n/2} + x_0$
 - $\text{num}_2 = y_1 * 10^{n/2} + y_0$
- Conquer: найдем произведения $x_1 * y_1$; $x_1 * y_0$; $x_0 * y_1$; $x_0 * y_0$
 - Произведение однозначных чисел выполняется за $O(1)$
- Combine: $\text{num}_1 * \text{num}_2 = (x_1 * 10^{n/2} + x_0)(y_1 * 10^{n/2} + y_0) =$
 $x_1 * y_1 * 10^n + (x_1 * y_0 + x_0 * y_1) * 10^{n/2} + x_0 * y_0$



Умножение чисел

- $x_1 * y_1 * 10^n + (x_1 * y_0 + x_0 * y_1) * 10^{n/2} + x_0 * y_0$
- Предположим, что:
 - Умножение на 10^N делаем сдвигом цифр в массиве => $O(N)$
 - Сложение делаем поразрядно с переносом. Разрядность цифр в формуле не превосходит $2N$ => $O(N)$
- $T(N) = 4T(N/2) + O(N)$
- $T(N) = \Theta(\text{ ? })$



Рекурсивное умножение

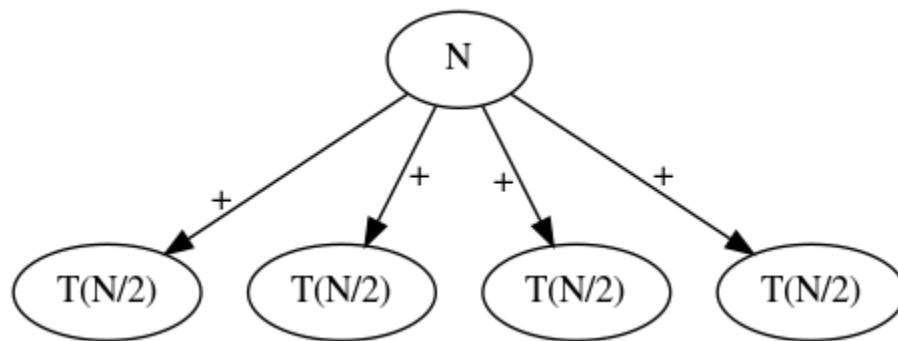
- $T(N) = 4T(N/2) + N$

$$T(N)$$



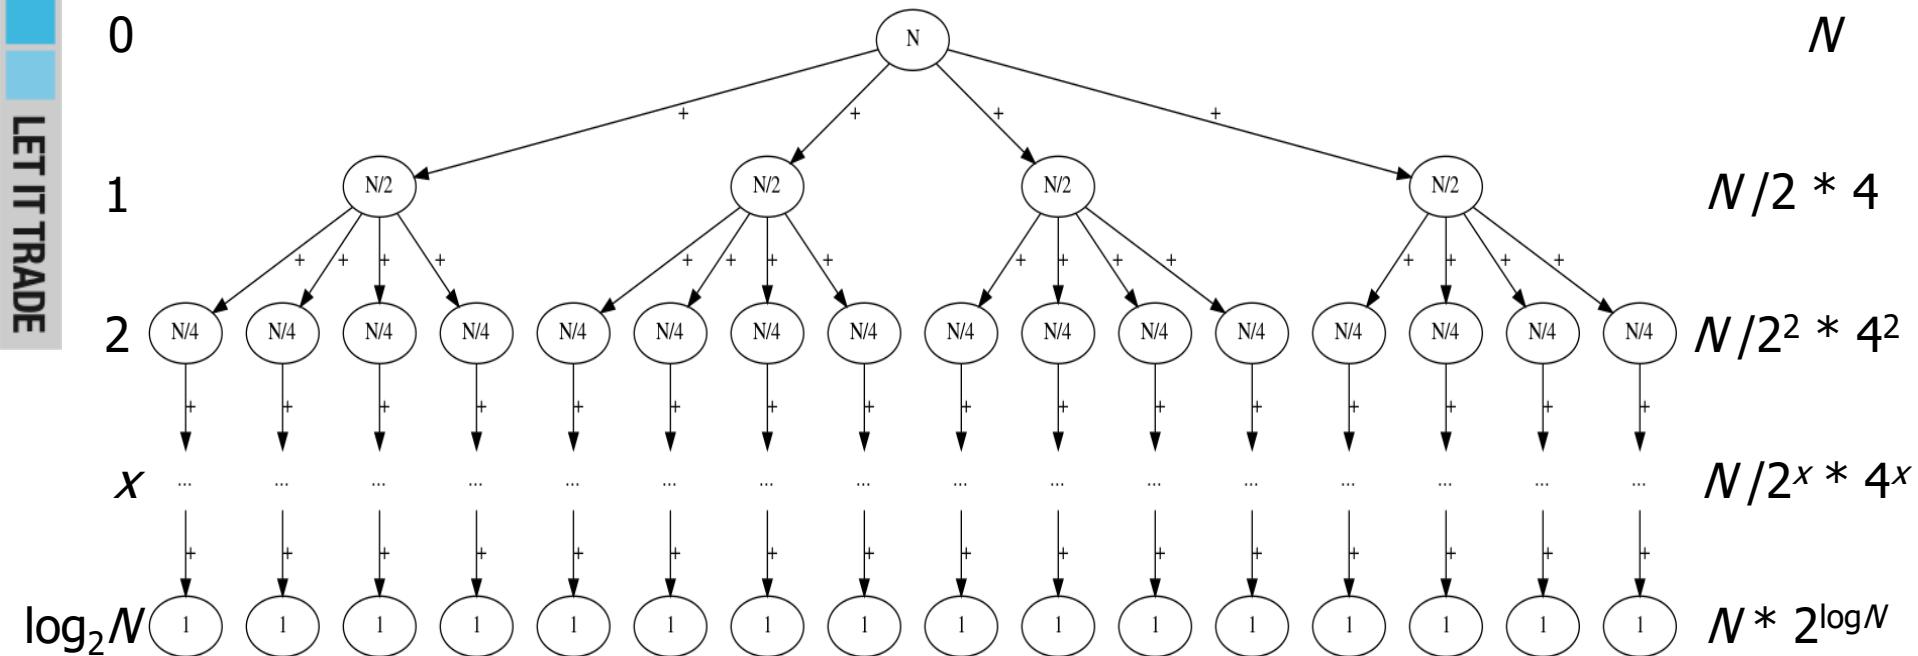
Рекурсивное умножение

- $T(N/2) = 4T(N/4) + N/2$



Рекурсивное умножение

- Каждая цифра из num_1 перемножается с каждой цифрой из $\text{num}_2 \Rightarrow N^2$ операций на нижнем уровне



- $T(N) = N(2^{\log N + 1} - 1) / (2 - 1) = N(2N - 1) = \Theta(N^2)$



Алгоритм Карацубы

- Divide: как и прежде
- Conquer: вместо четырех подзадач требуется решить три
 - $A = x_1 * y_1$
 - $B = x_0 * y_0$
 - $C = (x_1 + x_0)(y_0 + y_1)$
- Combine: $\text{num}_1 * \text{num}_2 = A * 10^n + (C - A - B) * 10^{n/2} + B$
 - $C - A - B = (x_1 + x_0)(y_0 + y_1) - x_1 * y_1 - x_0 * y_0 =$
 $= x_1 * y_0 + x_0 * y_1$
- $T(N) = 3T(N/2) + O(N)$
- $T(N) = \Theta(?)$



Алгоритм Карацубы

- Такое же число уровней дерева рекурсии, что и в предыдущем алгоритме

LET IT TRADE

$\log_2 N$

0

1

2

x

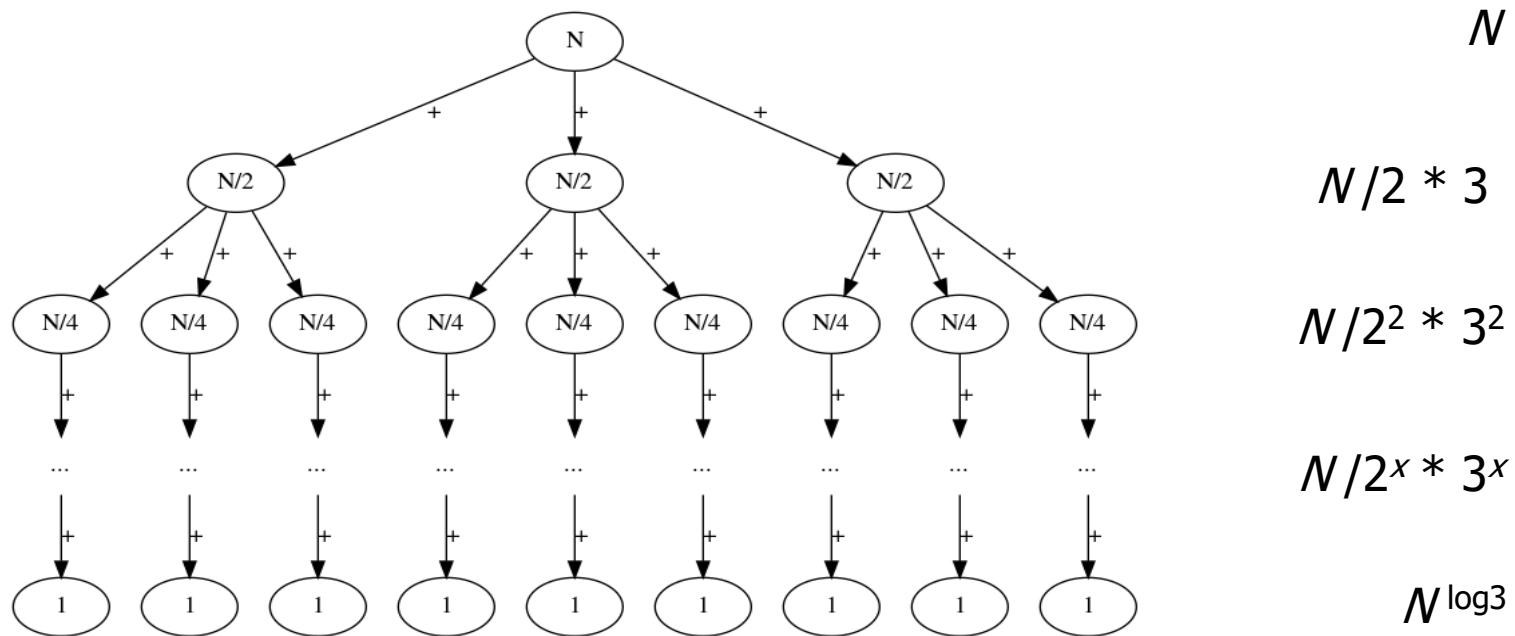
N

$N/2 * 3$

$N/2^2 * 3^2$

$N/2^x * 3^x$

$N^{\log 3}$



- $(3/2)^{\log N} * N = (3^{\log N} / 2^{\log N}) * N = (N^{\log 3} / N) * N = N^{\log 3}$
- $T(N) = \Theta(N^{\log 3})$ как сумма геом. прогрессии



Умножение полиномов

- $A(x) = \sum_{k=0}^n a_k x^k$ $B(x) = \sum_{k=0}^n b_k x^k$
- Divide: $A(x) = A_1(x) x^{\frac{n}{2}} + A_0(x)$ $B(x) = B_1(x) x^{\frac{n}{2}} + B_0(x)$
 - Пример: $1 + 3x + x^2 + 7x^3 = (1 + 3x) + x^2(1 + 7x)$
- Conquer (алгоритм Карацубы):
 - $C_2(x) = A_1(x) B_1(x)$
 - $C_1(x) = (A_0(x) + A_1(x))(B_0(x) + B_1(x)) - A_0(x) B_0(x) - A_1(x) B_1(x)$
 - $C_0(x) = A_0(x) B_0(x)$
- Combine: $A(x) B(x) = C_2(x) x^n + C_1(x) x^{\frac{n}{2}} + C_0(x)$



Содержание курса

- Введение в теорию алгоритмов
- **Алгоритмы сортировок**
- Структуры данных
 - Линейные структуры
 - Бинарные деревья поиска
 - Хеши и хеш-функции
- Алгоритмы на графах
 - Обходы графов в ширину и глубину
 - Минимальные остовные деревья
 - Поиск кратчайших путей в графе



Мотивация

- Одна из самых естественных и распространенных задач:
 - Словарь – слова расположены в алфавитном порядке
 - Рейтинг студентов – у кого больше баллов, тот выше в списке
 - Расписание поездов, самолетов – по времени прибытия / отправления
 - Многие алгоритмы требуют отсортированные входные данные: различные геометрические задачи, ORDER BY, GROUP BY, DISTINCT в СУБД, быстрое объединение структур данных (в т.ч. JOIN в СУБД) и т.д.



Мотивация

- Таблица "Customers"

| CustomerID | CustomerName | ContactName | Address | City | PostalCode | Country |
|-------------------|--|--------------------|----------------------------------|----------------|-------------------|----------------|
| 1 | Alfreds Futterkiste | Maria Anders | Obere Str. 57 | Berlin | 12209 | Germany |
| 2 | Ana Trujillo Emparedados y helados | Ana Trujillo | Avda. de la Constitución 2222 | México D.F. | 05021 | Mexico |
| 3 | Antonio Moreno Taquería | Antonio Moreno | Mataderos 2312 | México D.F. | 05023 | Mexico |
| 4 | Around the Horn | Thomas Hardy | 120 Hanover Sq. | London | WA1 1DP | UK |
| 5 | Berglunds snabbköp | Christina Berglund | Berguvsvägen 8 | Luleå | S-958 22 | Sweden |
| ... | ... | ... | ... | ... | ... | ... |

Мотивация Сортировка

■ Пример ORDER BY

```
1. SELECT CustomerID, Country  
2. FROM Customers  
3. ORDER BY Country;
```

| CustomerID | Country |
|------------|-----------|
| 12 | Argentina |
| 54 | Argentina |
| 64 | Argentina |
| 20 | Austria |
| 59 | Austria |
| 50 | Belgium |
| 76 | Belgium |
| 15 | Brazil |
| ... | ... |



Мотивация Агрегация

■ Пример GROUP BY

```
1. SELECT COUNT(CustomerID), Country  
2. FROM Customers  
3. GROUP BY Country;
```

| COUNT(CustomerID) | Country |
|-------------------|-----------|
| 3 | Argentina |
| 2 | Austria |
| 2 | Belgium |
| 9 | Brazil |
| 3 | Canada |
| 2 | Denmark |
| 2 | Finland |
| 11 | France |
| ... | ... |



Мотивация Дедупликация

■ Пример DISTINCT

1. SELECT DISTINCT Country FROM Customers;

Number of Records: 21

| Country |
|-----------|
| Argentina |
| Austria |
| Belgium |
| Brazil |
| Canada |
| Denmark |
| Finland |
| France |
| Germany |
| Ireland |
| ... |



Бинарный поиск

- Найдем идентификаторы всех таймзон:

```
TimeZoneIdentifier using_linear_str(const char * timezone_name)
{
    if (::strcmp(timezone_name, "America/Porto_Acre") == 0)
        { return TZ_STD_AMERICA_PORTO_ACRE; }
    if (::strcmp(timezone_name, "Australia/Perth") == 0)
        { return TZ_STD_AUSTRALIA_PERTH; }
    if (::strcmp(timezone_name, "Europe/Madrid") == 0)
        { return TZ_DST_EUROPE_MADRID; }

    ...
}
```

- Повторим эксперимент тысячу раз:

| | # | 50% | 95% | 99.9% |
|--------------------|------|---------|---------|---------|
| ===== | | | | |
| linear_str_begin - | | | | |
| linear_str_end | 1000 | 3831 µs | 4062 µs | 4530 µs |



Бинарный поиск

- Найдем идентификаторы всех таймзон:

```
TimeZoneIdentifier using_linear(const char * timezone_name)
{
    const uint32_t hash_key = hash(timezone_name);

    if (0x013129B9 == hash_key) { return TZ_STD_AMERICA_PORTO_ACRE; }
    if (0x014A1BF1 == hash_key) { return TZ_STD_AUSTRALIA_PERTH; }
    if (0x03C9E0D7 == hash_key) { return TZ_DST_EUROPE_MADRID; }

    ...
}
```

- Повторим эксперимент тысячу раз:

| | # | 50% | 95% | 99 . 9% |
|----------------|------|--------|--------|---------|
| ===== | | | | |
| linear_begin - | | | | |
| linear_end | 1000 | 122 µs | 140 µs | 439 µs |



Бинарный поиск

- Найдем идентификаторы всех таймзон:

```
TimeZoneIdentifier using_switch(const char * timezone_name)
{
    const uint32_t hash_key = hash(timezone_name);
    switch(hash_key)
    {
        case 0x013129B9: return TZ_STD_AMERICA_PORTO_ACRE;
        case 0x014A1BF1: return TZ_STD_AUSTRALIA_PERTH;
        case 0x03C9E0D7: return TZ_DST_EUROPE_MADRID;
    ...
}
```

- Повторим эксперимент тысячу раз:

| | # | 50% | 95% | 99 . 9% |
|----------------|------|-------|-------|---------|
| ===== | | | | |
| switch_begin - | | | | |
| switch_end | 1000 | 25 µs | 28 µs | 89 µs |



Бинарный поиск и сортировка

- Бинарный поиск:
 - $T(N) = O(1) + T(N/2)$
 - Число атомов во Вселенной $\sim 10^{80}$, найдем за ~ 260 шагов
 - ? $x_0 : f(x_0) = c$, $f(x)$ монотонно возрастает
- Сортировка:
 - Отношение порядка $<$ на множестве ключей:
 - Иррефлексивно и транзитивно
 - Трихотомия: $\forall a, b : (a < b) \vee (b < a) \vee (a = b)$
 - Игра «камень, ножницы, бумага»
- Задача сортировки - получить перестановку, в которой ключи расположены в порядке неубывания



Характеристики сортировок

- Оценка эффективности алгоритма сортировки:
 - Время работы алгоритма в лучшем, среднем и худшем случае
 - Объем используемой дополнительной памяти
- Свойства алгоритма сортировки:
 - Рекурсивность
 - Стабильность
 - Адаптивность
 - Тип (на основе сравнения, подсчета, ...)



Стабильность

| По времени | ->По фамилии (нестабильная) | ->По фамилии (стабильная) |
|-------------------|---|---|
| Петров 09.00 | Беляев 10.00 | Беляев 10.00 |
| Петров 10.00 | Иванов 12.00 | Иванов 11.00 |
| Беляев 10.00 | Иванов 11.00 | Иванов 12.00 |
| Торопов 11.00 | Косяков 13.00 | Косяков 13.00 |
| Иванов 11.00 | Петров 10.00 | Петров 09.00 |
| Иванов 12.00 | Петров 09.00 | Петров 10.00 |
| Косяков 13.00 | Торопов 11.00 | Торопов 11.00 |

Сортировка выбором

- Самый простой алгоритм сортировки: на каждой итерации находим минимум и кладем его в начало подмассива

```
1. void selection_sort(int * a, int n)
2. {
3.     for(int i = 0; i < n - 1; ++i) {
4.         for(int j = i + 1; j < n; ++j) {
5.             if (a[j] < a[i]) {
6.                 int t = a[i];
7.                 a[i] = a[j];
8.                 a[j] = t;
9.             }
10.        }
11.    }
12. }
```

- Инвариант: после i -ой итерации $a[0..i]$ отсортирован, каждый элемент из $a[i+1..n]$ не меньше $a[i]$



Сортировка выбором

- Самый простой алгоритм сортировки: на каждой итерации находим минимум и кладем его в начало подмассива

```
1. void selection_sort(int * a, int n)
2. {
3.     for(int i = 0; i < n - 1; ++i) {
4.         for(int j = i + 1; j < n; ++j) {
5.             if (a[j] < a[i]) {
6.                 int t = a[i];
7.                 a[i] = a[j];
8.                 a[j] = t;
9.             }
10.        }
11.    }
12. }
```

- Можно через рекурсию: $T(N) = O(N) + T(N-1)$



Сортировка выбором

```
1. void selection_sort(int * a, int n) {  
2.     for(int i = 0; i < n - 1; ++i) {  
3.         int min = i;  
4.         for(int j = i + 1; j < n; ++j) {  
5.             if (a[j] < a[min]) {  
6.                 min = j;  
7.             }  
8.         }  
9.         int t = a[i];  
10.        a[i] = a[min];  
11.        a[min] = t;  
12.    }  
13. }
```

- Оценка сложности: $\Theta(N^2)$
- Дополнительная память: $O(1)$



Сортировка пузырьком

```
1. void bubble_sort(int * a, int n) {  
2.     bool swap = true;  
3.     while(swap) {  
4.         swap = false; --n;  
5.         for(int i = 0; i < n; ++i) {  
6.             if (a[i + 1] < a[i]) {  
7.                 int t = a[i];  
8.                 a[i] = a[i + 1];  
9.                 a[i + 1] = t;  
10.                swap = true;  
11.            }  
12.        }  
13.    }  
14. }
```

- Оценка сложности: $O(N^2)$
- Дополнительная память: $O(1)$



Сортировка слиянием

- Метод «разделяй и властвуй» (divide-and-conquer):
 - 1) разделим задачу на подзадачи
 - 2) решаем подзадачи с использованием рекурсии
 - 3) объединяем решения подзадач в решение задачи



Сортировка слиянием

```
1. void merge_sort(int * a, int * aux, int l, int r) {  
2.     if (l < r) {  
3.         int m = (l + r) / 2;  
4.         merge_sort(a, aux, l, m);  
5.         merge_sort(a, aux, m + 1, r);  
6.         merge(a, aux, l, m, r);  
7.     }  
8. }
```

- Для заданного N делим задачу на подзадачи всегда одинаковым образом (в отличии от быстрой сортировки)
- Время работы алгоритма не зависит от входных данных (только от размера задачи)
- Основная работа – после выполнения рекурсивных вызовов при слиянии



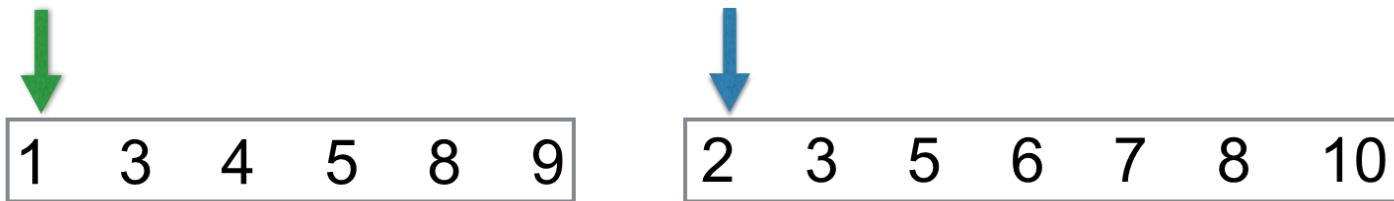
Сортировка слиянием

1 3 4 5 8 9

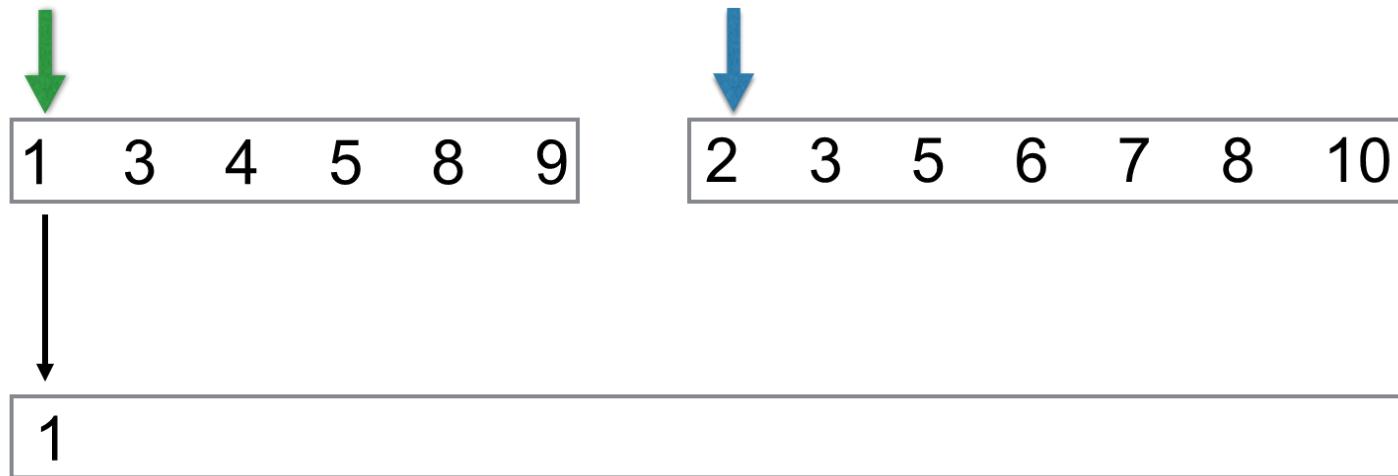
2 3 5 6 7 8 10



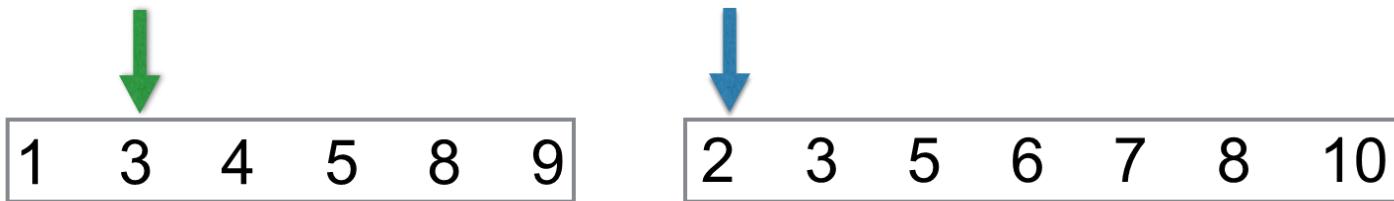
Сортировка слиянием



Сортировка слиянием

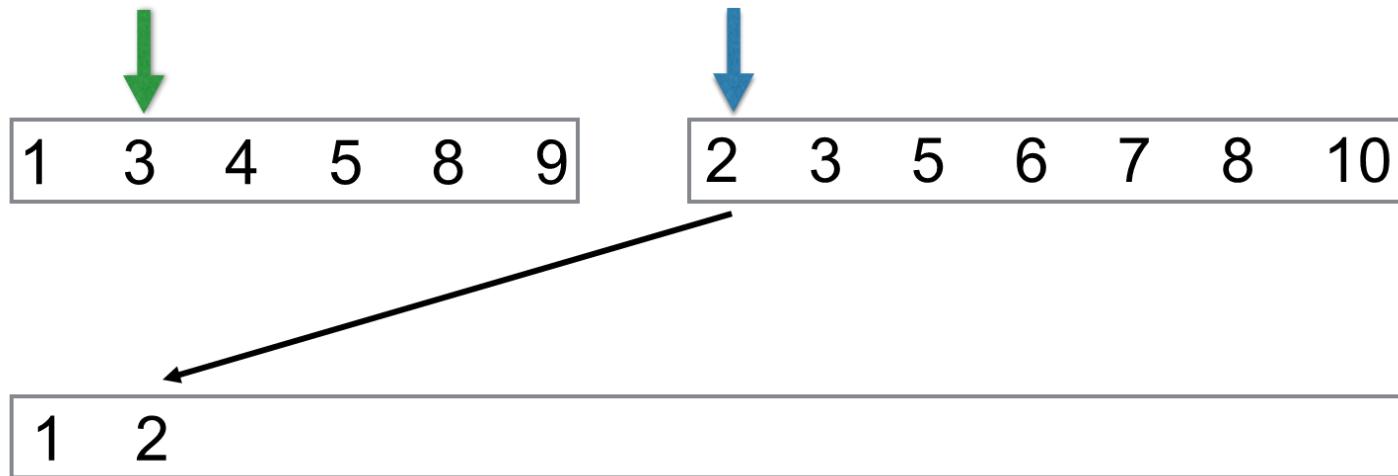


Сортировка слиянием

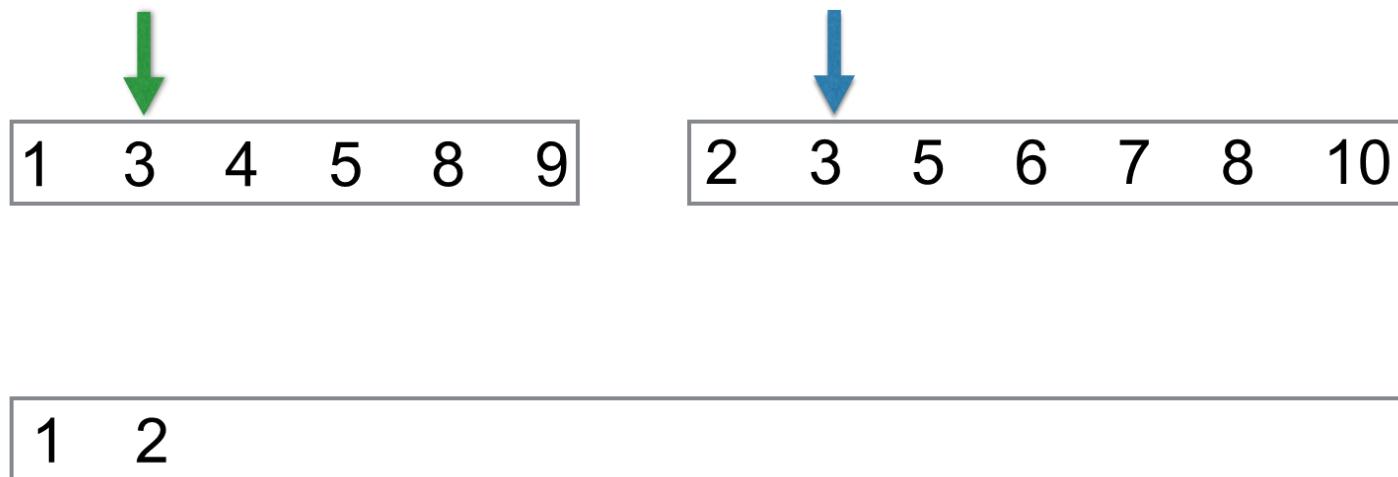


1

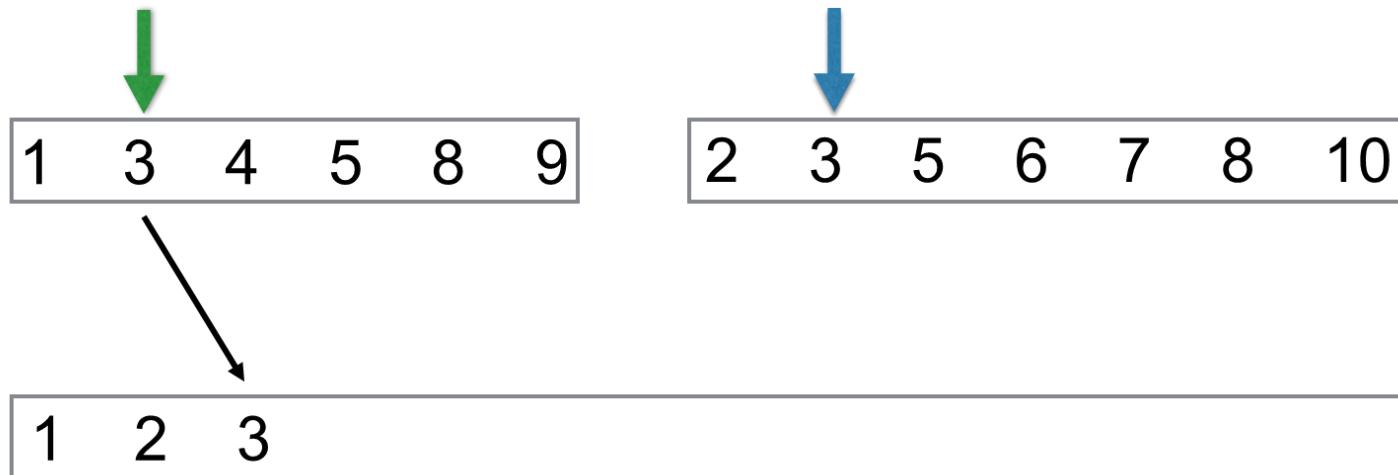
Сортировка слиянием



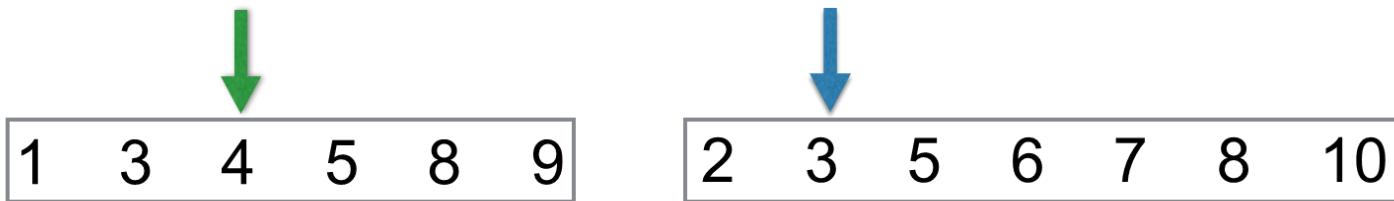
Сортировка слиянием



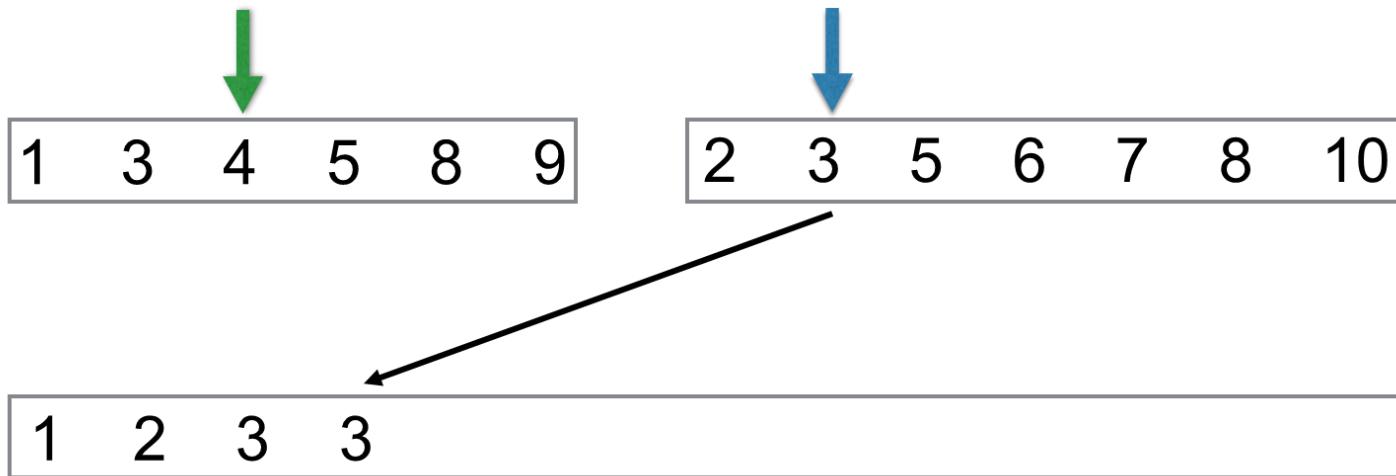
Сортировка слиянием



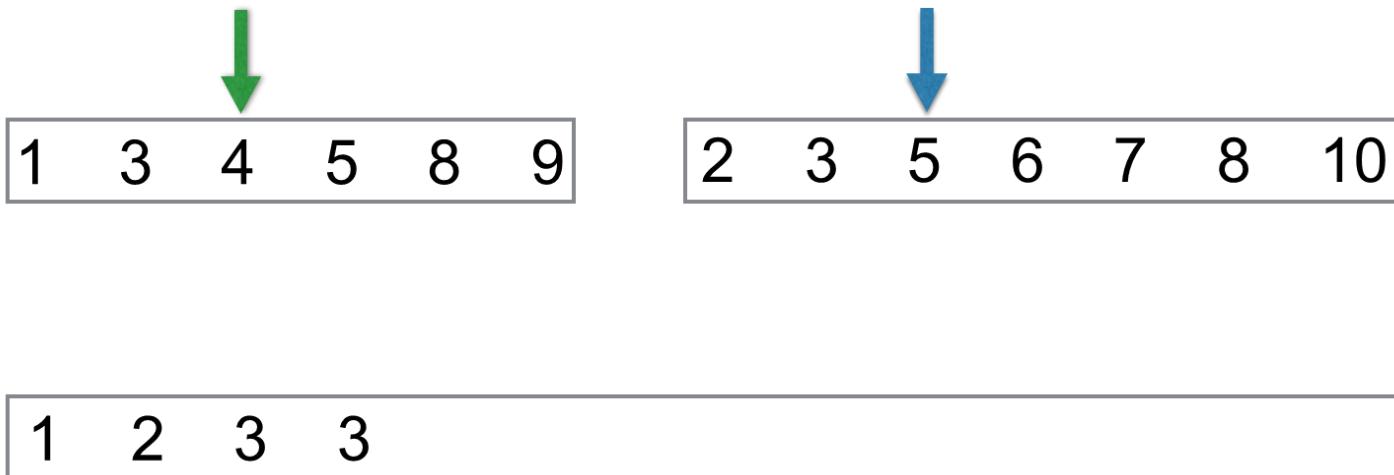
Сортировка слиянием



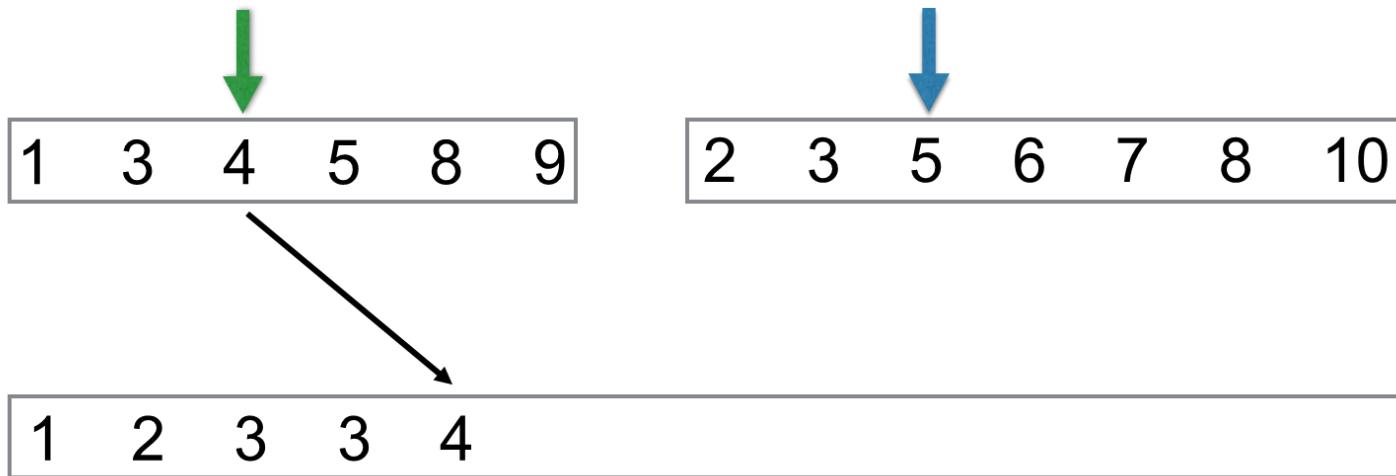
Сортировка слиянием



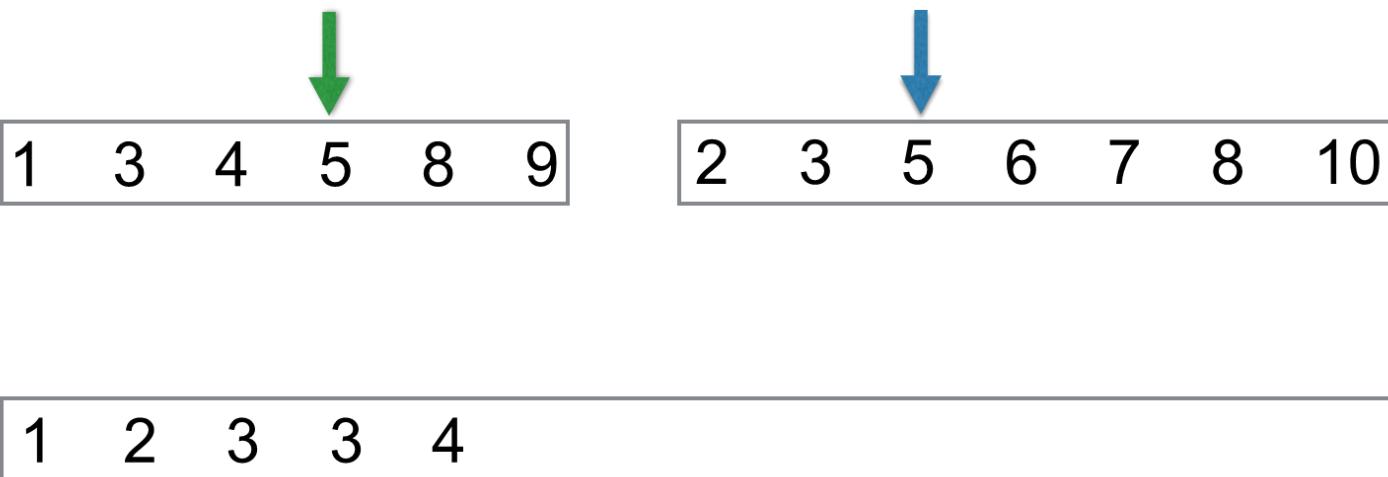
Сортировка слиянием



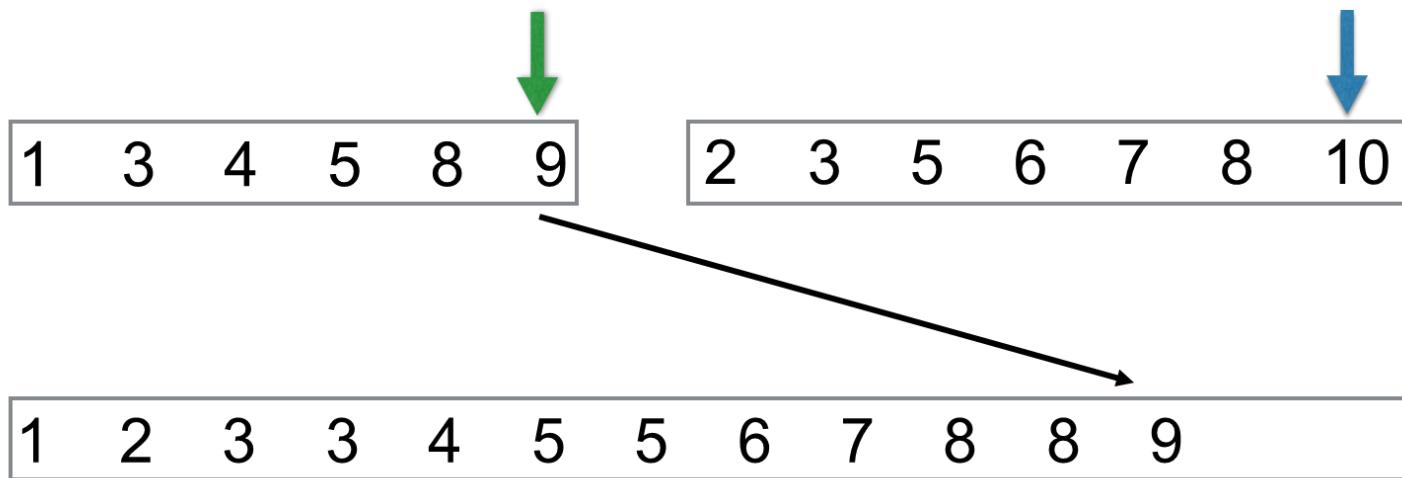
Сортировка слиянием



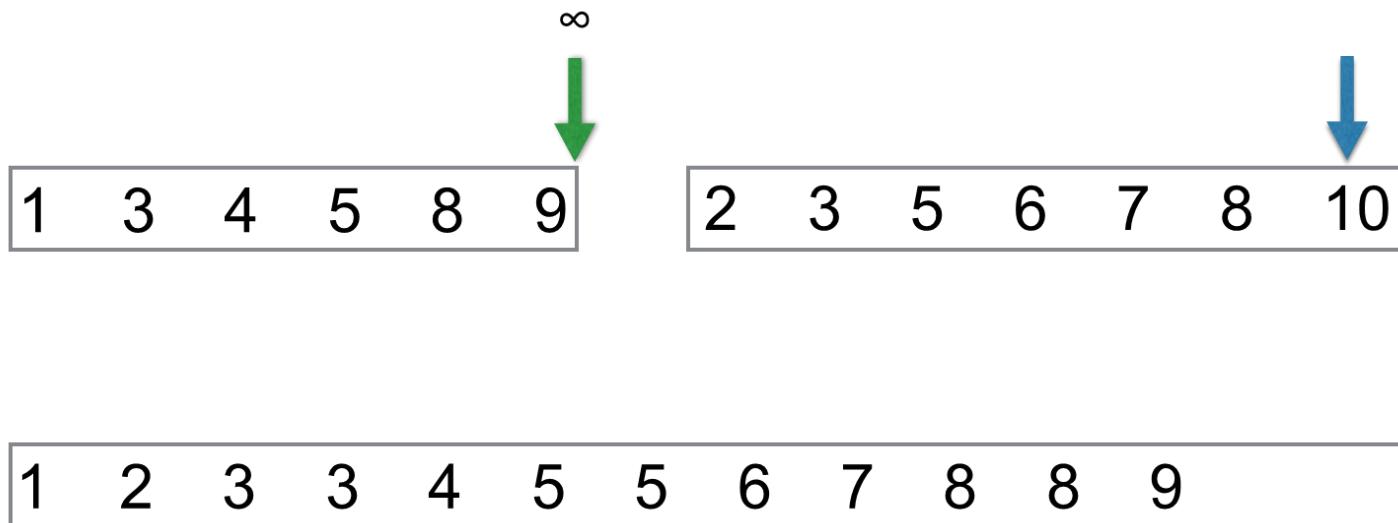
Сортировка слиянием



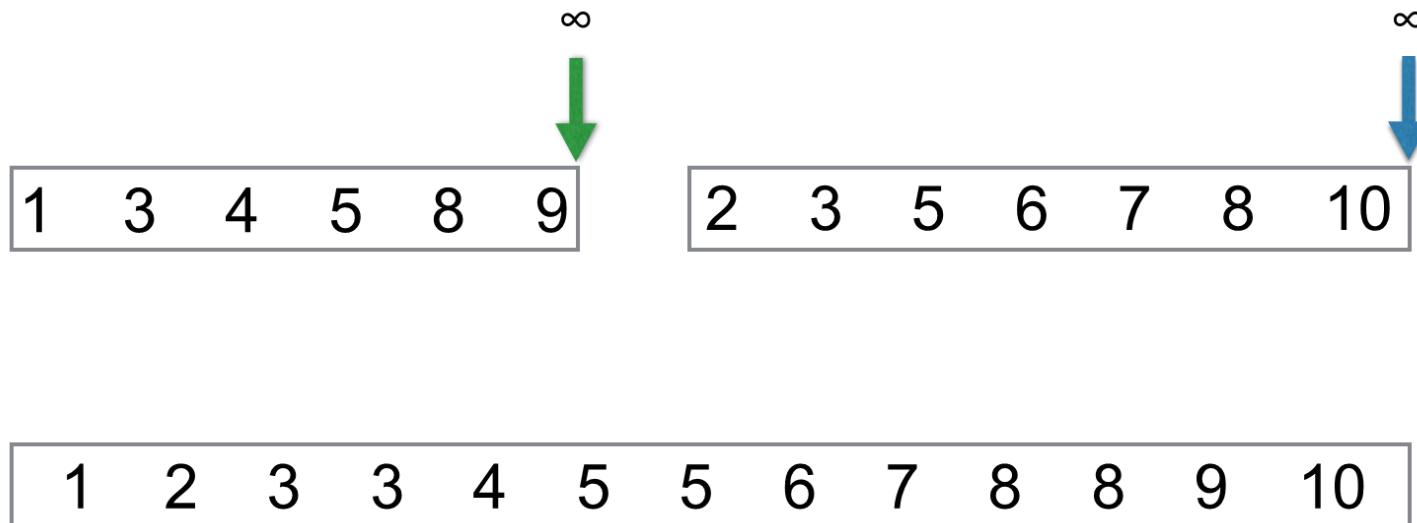
Сортировка слиянием



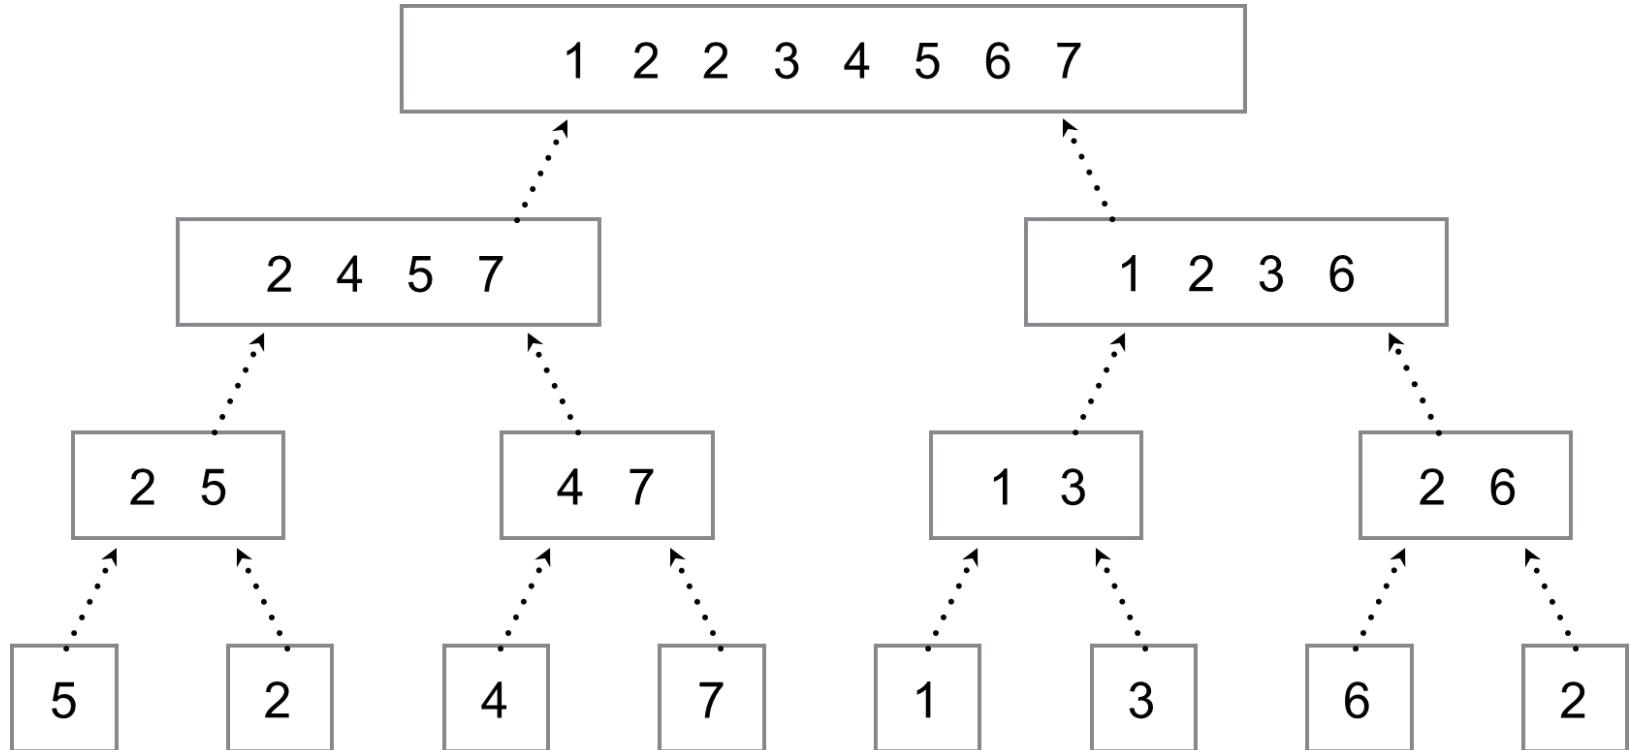
Сортировка слиянием



Сортировка слиянием



Сортировка слиянием



- $T(N) = \theta(N) + 2T(N/2)$
- Можно считать, что $N = 2^k$, т.е. $k = \log N$; почему?



Сортировка слиянием

■ Слияние

```
1. void merge(int * a, int * aux, int l, int m, int r) {  
2.     int i = l;  
3.     int j = m + 1;  
4.     for (int k = l; k <= r; ++k) aux[k] = a[k];  
5.  
6.     for (int k = l; k <= r; ++k) {  
7.         if (i > m) { a[k] = aux[j++]; continue; }  
8.         if (j > r) { a[k] = aux[i++]; continue; }  
9.         if (aux[j] < aux[i]) { a[k] = aux[j++]; }  
10.        else { a[k] = aux[i++]; }  
11.    }  
12.}
```

- Стабильная; в C++ `std::stable_sort` – обычно сортировка слиянием
- Оценка сложности: $\Theta(N \log N)$; доп. память: $O(N)$



Сортировка слиянием

- Слияние через битонический (bitonic) порядок

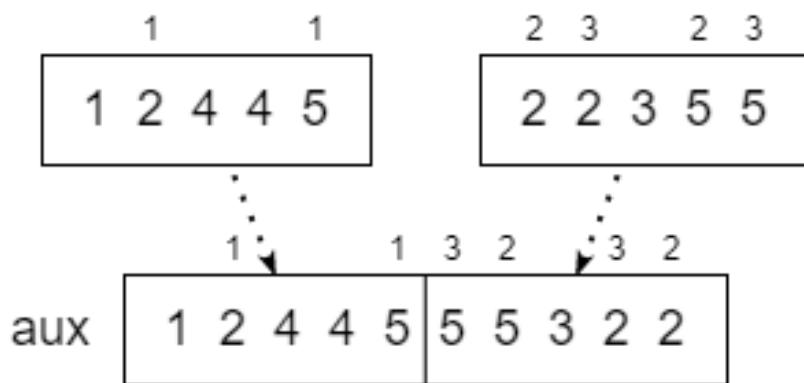
```
1. void merge_bitonic(int * a, int * aux, int l, int m, int r) {  
2.     int i, j;  
3.     for (i = m + 1; i > l; --i) aux[i-1] = a[i-1];  
4.     for (j = m; j < r; ++j) aux[r+m-j] = a[j+1];  
5.     for (int k = l; k <= r; ++k) {  
6.         if (aux[j] < aux[i]) {  
7.             a[k] = aux[j--];  
8.         } else {  
9.             a[k] = aux[i++];  
10.        }  
11.    }  
12. }
```

- Стабильность?



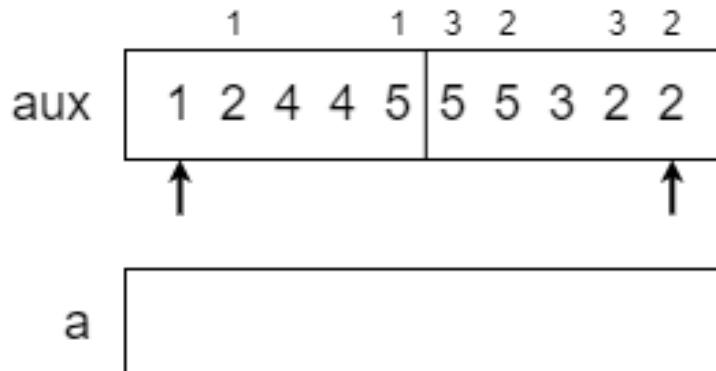
Слияние через битонический порядок

- ```
3. for (i = m + 1; i > l; --i) aux[i-1] = a[i-1];
4. for (j = m; j < r; ++j) aux[r+m-j] = a[j+1];
```



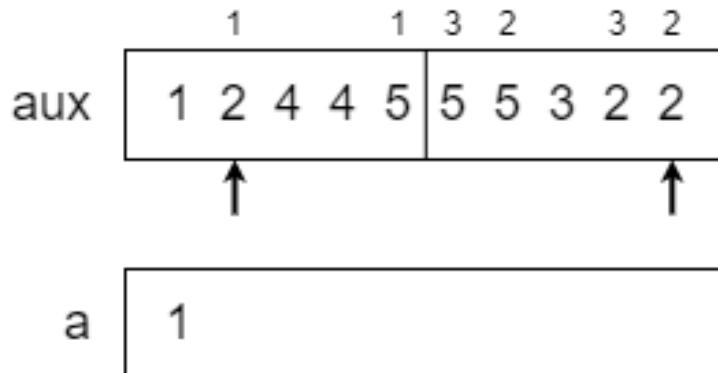
# Слияние через битонический порядок

```
5. for (int k = 1; k <= r; ++k) {
6. if (aux[j] < aux[i]) {
7. a[k] = aux[j--];
8. } else {
9. a[k] = aux[i++];
10. }
11. }
```



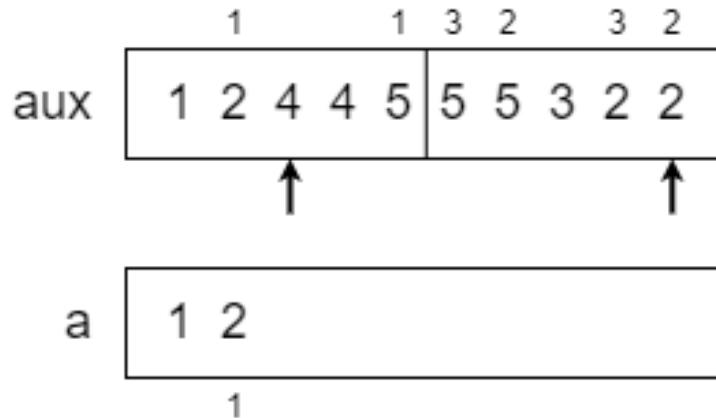
# Слияние через битонический порядок

```
5. for (int k = 1; k <= r; ++k) {
6. if (aux[j] < aux[i]) {
7. a[k] = aux[j--];
8. } else {
9. a[k] = aux[i++];
10. }
11. }
```



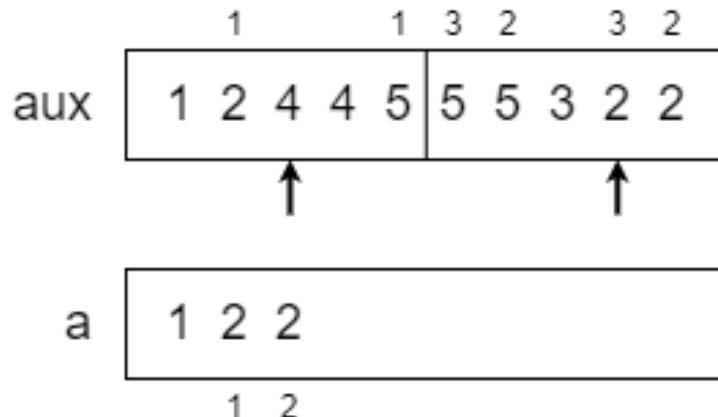
# Слияние через битонический порядок

```
5. for (int k = 1; k <= r; ++k) {
6. if (aux[j] < aux[i]) {
7. a[k] = aux[j--];
8. } else {
9. a[k] = aux[i++];
10. }
11. }
```



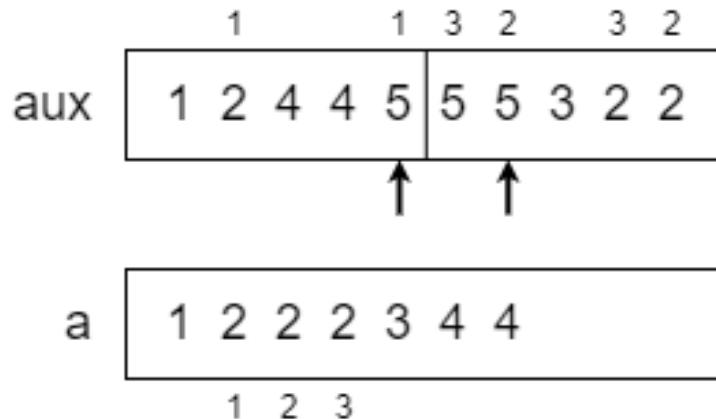
# Слияние через битонический порядок

```
5. for (int k = 1; k <= r; ++k) {
6. if (aux[j] < aux[i]) {
7. a[k] = aux[j--];
8. } else {
9. a[k] = aux[i++];
10. }
11. }
```



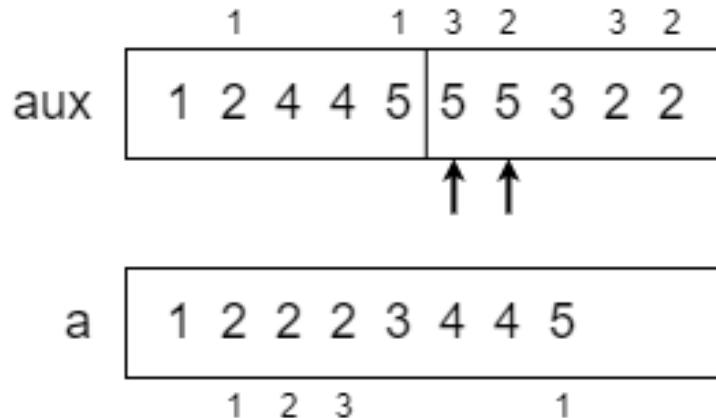
# Слияние через битонический порядок

```
5. for (int k = 1; k <= r; ++k) {
6. if (aux[j] < aux[i]) {
7. a[k] = aux[j--];
8. } else {
9. a[k] = aux[i++];
10. }
11. }
```



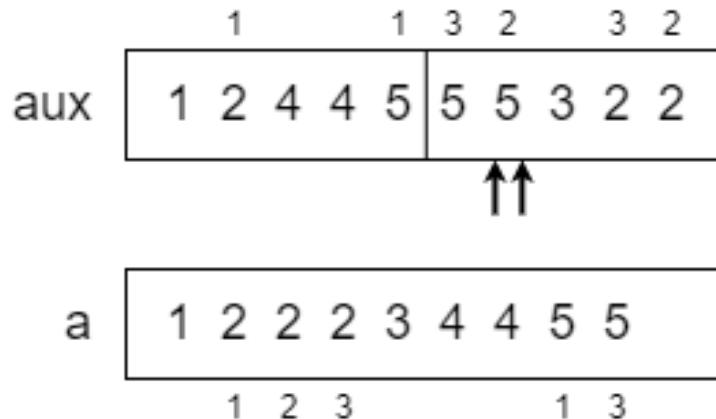
# Слияние через битонический порядок

```
5. for (int k = 1; k <= r; ++k) {
6. if (aux[j] < aux[i]) {
7. a[k] = aux[j--];
8. } else {
9. a[k] = aux[i++];
10. }
11. }
```



# Слияние через битонический порядок

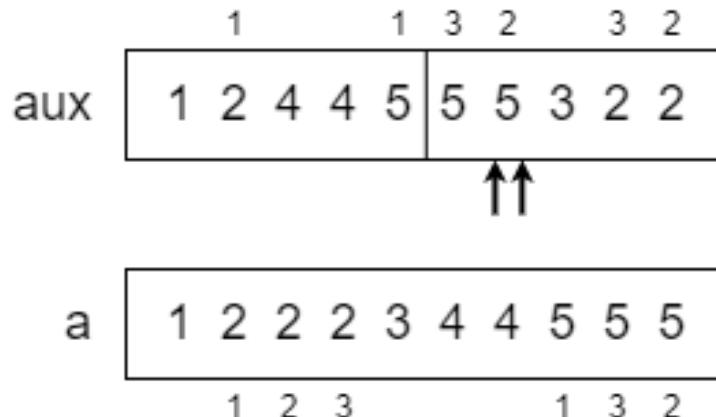
```
5. for (int k = 1; k <= r; ++k) {
6. if (aux[j] < aux[i]) {
7. a[k] = aux[j--];
8. } else {
9. a[k] = aux[i++];
10. }
11. }
```



# Слияние через битонический порядок

```

5. for (int k = 1; k <= r; ++k) {
6. if (aux[j] < aux[i]) {
7. a[k] = aux[j--];
8. } else {
9. a[k] = aux[i++];
10. }
11. }
```



- Реализация нестабильна!



# Сортировка слиянием

- Устранение копирования при merge

```
1. void sort(int * a, int N) {
2. int * aux = new int[N];
3. for (int k = 0; k < N; ++k) aux[k] = a[k];
4. merge_sort(a, aux, 0, N-1);
5. delete[] aux;
6. }
```

```
1. void merge_sort(int * a, int * aux, int l, int r) {
2. if (l < r) {
3. int m = (l + r) / 2;
4. merge_sort(aux, a, l, m);
5. merge_sort(aux, a, m + 1, r);
6. merge(a, aux, l, m, r);
7. }
8. }
```



# Bottom-Up сортировка слиянием

- Альтернатива Top-Down
- Нерекурсивная версия
- Пройдемся по массиву и сольем подмассивы размера 1
- Продолжим далее для подмассивов размера 2, 4, 8, ...
- Обход в обратном порядке vs Обход по уровням снизу вверх
- Дерево рекурсии и последовательность слияний для Top-Down при  $N = 5$ : 1-1; 2-1; 1-1; 3-2 (всего 12 per element слияний)
- Последовательность слияний для Bottom-Up при  $N = 5$ : 1-1; 1-1; 2-2; 4-1 (всего 13 per element слияний)
- Немного медленнее рекурсивной Top-Down версии



# Bottom-Up сортировка слиянием

```
1. void merge_sort_BU(int * a, int * aux, int l, int r) {
2. for (int sz = 1; sz <= r-l; sz = sz+sz)
3. for (int i = l; i <= r-sz; i += sz+sz)
4. merge(a, aux, i, i+sz-1, min(i+sz+sz-1, r));
5. }
```

- Последовательность слияний при  $N = 5$

```
sz = 1
merge(a, aux, 0, 0, 1)
merge(a, aux, 2, 2, 3)
```

```
sz = 2
merge(a, aux, 0, 1, 3)
```

```
sz = 4
merge(a, aux, 0, 3, 4)
```



# Sort-Merge JOIN

- Таблица "Customers"

| <b>CustomerID</b> | <b>CustomerName</b>                | <b>ContactName</b> | <b>Country</b> |
|-------------------|------------------------------------|--------------------|----------------|
| 1                 | Alfreds Futterkiste                | Maria Anders       | Germany        |
| 2                 | Ana Trujillo Emparedados y helados | Ana Trujillo       | Mexico         |
| 3                 | Antonio Moreno Taquería            | Antonio Moreno     | Mexico         |
| ...               | ...                                | ...                | ...            |

- Таблица "Orders"

| <b>OrderID</b> | <b>CustomerID</b> | <b>OrderDate</b> |
|----------------|-------------------|------------------|
| 10308          | 2                 | 1996-09-18       |
| 10309          | 37                | 1996-09-19       |
| 10310          | 77                | 1996-09-20       |
| ...            | ...               | ...              |



# Sort-Merge JOIN

- Пример (INNER) JOIN

```

1. SELECT Orders.OrderID, Customers.CustomerName, Orders.OrderDate
2. FROM Orders
3. INNER JOIN Customers
4. ON Orders.CustomerID=Customers.CustomerID;

```

| <b>OrderID</b> | <b>CustomerName</b>                | <b>OrderDate</b> |
|----------------|------------------------------------|------------------|
| 10308          | Ana Trujillo Emparedados y helados | 1996-09-18       |
| 10309          | Hungry Owl All-Night Grocers       | 1996-09-19       |
| 10310          | The Big Cheese                     | 1996-09-20       |
| 10311          | Du monde entier                    | 1996-09-20       |
| 10312          | Die Wandernde Kuh                  | 1996-09-23       |
| ...            | ...                                | ...              |

- The worst case scenario is if the join attribute for all the tuples in both tables contain the same value

# Обновление таблицы

- «На проволоке» таблица лежит по строкам

|          | <b>11</b> | <b>22</b> | <b>33</b> |
|----------|-----------|-----------|-----------|
| <b>1</b> | X         | 5         | hello     |
| <b>2</b> | Y         | 10        | world     |
| <b>3</b> | Z         | 15        | string    |
| <b>4</b> | X         | 11        | string    |
| <b>5</b> | X         | 13        | itmo      |

2.11 = Z

1.11 = A

1.22 = 0

**1.22 = 0**

2.33 = bye

=>

**1.22 = 1**

1.22 = 1

2.11 = Z

1.11 = A

2.33 = bye



# Большие объекты

- Дан массив больших объектов:
  - $B = \langle obj_1, obj_2, \dots, obj_N \rangle$
- Как лучше отсортировать его?



# Большие объекты

- Дан массив больших объектов:
  - $B = \langle obj_1, obj_2, \dots, obj_N \rangle$
- Можно отсортировать указатели на объекты или индексы:
  - $I = \langle 1, 2, \dots, N \rangle$
  - Сортируем  $I$  так, чтобы выполнялось следующее условие:
  - $B[I[1]] \leq B[I[2]] \leq \dots \leq B[I[N]]$



# Число инверсий

- Число инверсий в массиве  $A []$  равно числу пар  $(i, j)$ , таких, что  $i < j$  и  $A [i] > A [j]$
- Используется для оценки численной схожести нескольких списков с рейтингом (оценками) пользователей (numerical similarity measure between ranked lists)
- Сколько инверсий в массиве: 1, 2, 3, 4, 5, 6, 7, 8 ?
- Сколько инверсий в массиве: 1, 4, 5, 3, 2, 6, 7, 8 ?
  - Как вы считали? Какая сложность подсчета?
  - Число инверсий определяется числом пересечений отрезков, соединяющих одинаковые элементы



# Число инверсий

- Метод «разделяй и властвуй»
- Хотим  $\Theta(N \log N)$
- Используем сортировку слиянием
  - Левая и правая инверсия (можем посчитать рекурсивно)
  - Расщепленная инверсия (как посчитать за линейное время ?)
- Если в массиве  $A []$  отсутствуют расщепленные инверсии, как соотносятся левый и правый подмассивы  $A []$  ?
- Число расщепленных инверсий, включающих элемент  $a_j$  из правого подмассива, совпадает с числом элементов в левом подмассиве на момент копирования  $a_j$



# Коэффициент ранговой корреляции Кендалла

- С помощью сортировки и нехитрой математики Алиса легко сможет выбрать, с кем пойти в кино

| <b>ID</b> | <b>Фильм</b>    | <b>Алиса</b> | <b>Вася</b> | <b>Саша</b> |
|-----------|-----------------|--------------|-------------|-------------|
| <b>1</b>  | Звездные войны  | 6            | 5           | 1           |
| <b>2</b>  | Терминатор      | 5            | 6           | 2           |
| <b>3</b>  | Аватар          | 2            | 2           | 5           |
| <b>4</b>  | Властелин колец | 3            | 1           | 4           |
| <b>5</b>  | Гарри Поттер    | 4            | 4           | 3           |
| <b>6</b>  | Титаник         | 1            | 3           | 6           |

$$\tau = \frac{\text{число пар в одном порядке} - \text{число инверсий}}{\text{число всех пар}}$$



# Алгоритмы сортировок

Спасибо за  
внимание!