

Методы оптимизации ИТМО, 2 курс, 4 семестр

Лекция №5 Задачи оптимизации в машинном обучении

Запорожцев Иван Федорович
zaporozhtsev.if.work@gmail.com

План

1. Датасет, матрица «объект-признак».
2. Мнемоническое правило для определения понятия «машинное обучение»
3. Задачи классического машинного обучения. Loss-функция
4. Обучение с учителем, связь с прямой и обратной задачами моделирования.
5. Линейная регрессия. Связь коэффициентов одномерной линейной регрессии со статистическими свойствами случайных величин.
6. Многомерная линейная регрессия. Loss-функции MSE, MAE.
7. Вероятностный смысл MSE, MAE (связь с задачей максимизации правдоподобия).
8. Лучшие модели в классе констант в смысле минимизации MSE (MAE).
9. Обобщенная линейная регрессия, методы оптимизации для Loss-функций.
10. Регуляризация в задаче регрессии. Вероятностный смысл MSE+L2 (т. Байеса).
11. Составные Loss-функции в практических приложениях.

Датасет: объекты и признаки

Матрица «Объект – признак»

	Признак 1	Признак 2		Признак n
Объект 1	x11	x12		x1m
Объект 2	x21	x22		x2m
.....				
Объект m	xm1	xm2		xmm

MyShared


Датасет (dataset) – выборка многомерной случайной величины (СВ).

Признак как аналог неизвестной, одномерной СВ («фича», feature).

Целевой признак – моделируемый признак («таргет», target)

Для противопоставления моделируемого признака моделирующим вводят термины: регрессант и регрессоры, предиктант и предикторы.

Модель черного ящика



Выход модели называют также **предсказанием (prediction)**.

«Черный ящик» – такая модель умеет по входам вычислять выход, внутренняя структура не известна.

«Белый ящик» («серый ящик») – модель, о которой известно всё (почти всё).

Machine Learning: определение через пример

Машинное обучение – итерационный процесс обновления весов с целью уменьшения ошибки (loss – «потери», residue, residual – остаток, невязка).

Машинное обучение – итерационный процесс обновления параметров модели с целью решения оптимизационной задачи.

$$z = 2x + 3y = a_1x + a_2y$$

x, y, z

Номер итерации обучения	a1	a2	Ошибка (error, loss)
0	0.1	0.4	1000
...	...	...	...
19	1.99	2.99	0.001
20	1.9999	3.00001	0.000001
21	1.99999	3.000001	0.00000009


Целевая функция (loss – функция потерь), область поиска – ?

Начальное приближение (инициализация) – ?

Критерий останова – ?

Оптимизатор (=метод оптимизации) – ?

Задачи классического ML



Задачи оптимизации для обучения с учителем

$$y = f(x), \quad y = a(x, w)$$

- *Прямая задача моделирования:*

$$x^* \Rightarrow y^* : y^* = f(x^*)$$

$$x^*, w^* \Rightarrow y^* = a(x^*, w^*)$$

- *Обратная задача моделирования:*

$$y^* \Rightarrow x^* : y^* = f(x^*)$$

$$y^*, x^* \Rightarrow w^* : y^* = a(x^*, w^*)$$

$$y^*, x^* \Rightarrow w^* = \arg \min_w |y^* - a(x^*, w)|$$

$$y^*, x^*, g^* \Rightarrow w^* = \arg \min_w |y^* - a(x^*, g^*, w)|$$

Векторы: x – входы (признаки одного объекта), w – веса, g – гиперпараметры
 y – выход (скаляр),

Обучение с учителем (Supervised Learning)



Матрица, вектор, скаляр?

Линейная регрессия

Гипотеза о линейной зависимости целевой переменной, ищем решение в виде:

$$a(X_1, \dots, X_n) = w_0 + w_1 X_1 + \dots + w_n X_n$$



Практика:

- часто неплохо работает и при монотонных зависимостях
- хорошо работает, когда есть много «однородных» признаков




Цель – число продаж на следующей неделе

- признак 1 – число заходов на страницу продукта
- признак 2 – число добавлений в корзину
- признак 3 – число появлений продукта в поисковой выдаче
- ...

Линейная регрессия от одной переменной

$$a(X_1) = w_0 + w_1 X_1$$



Обучение:

$$\{(x_1, y_1), \dots, (x_m, y_m)\}, x_i \in \mathbb{R}$$

Хотели бы...

$$\begin{cases} w_0 + w_1 x_1 = y_1 \\ \dots \\ w_0 + w_1 x_m = y_m \end{cases}$$

Невязки / отклонения (residuals):

$$e_1 = y_1 - w_0 - w_1 x_1$$

...

$$e_m = y_m - w_0 - w_1 x_m$$

Линейная регрессия от одной переменной

Нетрудно показать:

$$w_1 = \frac{\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^m (x_i - \bar{x})^2} = \frac{\text{cov}(\{x_i\}, \{y_i\})}{\text{var}(\{x_i\})},$$

$$w_0 = \bar{y} - w_1 \bar{x},$$

$$\text{где } \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i, \bar{y} = \frac{1}{m} \sum_{i=1}^m y_i.$$

Полученное уравнение прямой
(проходит через «центр масс»):

$$(y - \bar{y}) = \frac{\text{cov}(\{x_i\}, \{y_i\})}{\text{var}(\{x_i\})} (x - \bar{x})$$

Общий случай

Многих
переменных

$$a(X_1, \dots, X_n) = w_0 + w_1 X_1 + \dots + w_n X_n = x^T w$$

веса (параметры) – $w = (w_0, w_1, \dots, w_n)^T$

объект – $x = (X_0, X_1, \dots, X_n)^T$

$X_0 \equiv 1$ – фиктивный признак для удобства

обучение: $\{(x_1, y_1), \dots, (x_m, y_m)\} \quad x_i \in \mathbf{R}^{n+1}$


опять хотим решить $Xw = y$

$$\begin{cases} x_1^T w = y_1 \\ \dots \\ x_m^T w = y_m \end{cases}$$

Как решать?

Loss-функции MSE и MAE

Mean Squared Error (MSE): $\frac{1}{2m} \|Xw - y\|_2^2 = \frac{1}{2m} \sum_{i=1}^m (y_i - x_i^T w)^2 \rightarrow \min_w,$



Mean Absolute Error (MAE): $\frac{1}{m} \|Xw - y\|_1 = \frac{1}{m} \sum_{i=1}^m |y_i - x_i^T w| \rightarrow \min_w$

Вероятностный смысл MSE и MAE

$$\text{Mean Squared Error (MSE)}: \frac{1}{2m} \|Xw - y\|_2^2 = \frac{1}{2m} \sum_{i=1}^m (y_i - x_i^T w)^2 \rightarrow \min_w,$$

Задача минимизации MSE эквивалентна задаче максимизации правдоподобия выборки невязок, если считать, что невязка является случайной величиной, распределенной по нормальному закону с нулевым математическим ожиданием.


Задача минимизации MAE эквивалентна задаче максимизации правдоподобия выборки невязок, если считать, что невязка является случайной величиной, распределенной по закону Лапласа с нулевым математическим ожиданием.

См. дополнительный материал к лекции

Оптимальные модели в классе констант (в смысле минимизации MSE)


$$MSE = \frac{1}{2m} \sum_{i=1}^m (y_i - a(x_i, w))^2 \rightarrow \min_w$$

$$a = \frac{1}{m} \sum_{i=1}^m y_i \quad ?$$



Оптимальные модели в классе констант (в смысле минимизации MAE)

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - a(x_i, w)| \rightarrow \min_w \Rightarrow \sum_{i=1}^m |y_i - a(x_i, w)| \rightarrow \min_w$$




$$a = \text{median}(\{y_i\}_{i=1}^m) ?$$

Оптимальные модели в классе констант (в смысле минимизации MAE)

$$\sum_{i=1}^m |y_i - a(x_i, w)| \rightarrow \min_w \quad a = \text{median}(\{y_i\}_{i=1}^m)$$

$$f(x) = |x - 3| + |x| + |x + 3| + |x + 5|$$

Как видим, функция зависит от четырёх модулей. Нанесём на числовую ось точки, в которых выражения под модулем обращаются в ноль.





	I	II	III	IV	V
	$(-\infty; -5)$	$[-5; -3)$	$[-3; 0)$	$[0; 3)$	$[3; +\infty)$
$x - 3$	-	-	-	-	+
x	-	-	-	+	+
$x + 3$	-	-	+	+	+
$x + 5$	-	+	+	+	+
$f(x)$	$3 - x - x - x -$ $-3 - x - 5$	$-x + 3 - x - x -$ $-3 + x + 5$	$-x + 3 - x + x +$ $+3 + x + 5$	$-x + 3 + x + x +$ $+3 + x + 5$	$x - 3 + x + x +$ $+3 + x + 5$

Оптимальные модели в классе констант (в смысле минимизации MAE)

$$\sum_{i=1}^m |y_i - a(x_i, w)| \rightarrow \min_w$$

$$a = \text{median}(\{y_i\}_{i=1}^m)$$



Решение задачи минимизации: прямой метод

$$\|Xw - y\|_2^2 \rightarrow \min_w$$

Метод наименьших квадратов (OLS, Ordinary Least Squares)

$$\|Xw - y\|_2^2 = (Xw - y)^T (Xw - y) = w^T X^T X w - w^T X^T y - y^T X w + y^T y$$

$$\nabla \|Xw - y\|_2^2 = 2X^T X w - 2X^T y = 0$$

$X^T X w = X^T y$ решение существует, если столбцы л/н

$$w = (X^T X)^{-1} X^T y \text{ помним, что } \text{rg}(X^T X) = \text{rg}(X)$$

$$(X^T X)^{-1} X^T$$

псевдообратная матрица Мура-Пенроуза
обобщение обратной на неквадратные матрицы

Обобщённая линейная регрессия: вместо X – что угодно

Выражаем целевое значение через л/к базисных функций (они фиксированы)

$$a(X_1, \dots, X_n) = w_0 + w_1 \varphi_1(X_1, \dots, X_n) + \dots + w_k \varphi_k(X_1, \dots, X_n)$$

$$C_{Ni}(I_{Ni}, I_{Cu}, I_{Fe}) = w_0 + w_1 I_{Ni} + w_2 \frac{1}{I_{Cu}} + w_3 \frac{I_{Cu}}{I_{Fe}}$$

FEATURE GENERATION



PATIENT ID	PATIENT AGE	NUMBER OF DIAGNOSES	AGE X NUMBER DIAGNOSES
55629189	15	9	135
86057875	25	6	150
82442376	35	7	245
42519267	45	5	225
82637451	55	9	495
114882984	65	7	455
48330782	75	8	600

Методы оптимизации Loss для линейной регрессии, обобщенной линейной регрессии, нелинейной регрессии...

Зная свойства Loss (или предполагая их для упрощения – в практических приложениях), можно использовать ранее рассмотренные методы, в частности:

- метод градиентного спуска и его модификации,
- Метод Ньютона и квазиньютоновские методы,
- и т.д.

Регуляризация:

Упрощённое объяснение смысла

$$a(X_1, \dots, X_n) = w_0 + w_1 X_1 + \dots + w_n X_n$$

Если есть два похожих объекта,
то должны быть похожи метки, пусть
отличаются в j -м признаке, тогда
ответы модели отличаются на $\varepsilon_j w_j$

Поэтому не должно быть очень больших
по модулю весов (у признаков,
по которым могут отличаться
похожие объекты)

Поэтому вместе с $\|Xw - y\|_2^2 \rightarrow \min$

хотим $\|w\|_2^2 \rightarrow \min$



Не на все коэффициенты
нужна регуляризация!

Почему?

Регуляризация L1 (LASSO-регрессия) и L2 (Ridge-регрессия)

$$\begin{aligned} L1: \|Xw - y\|_2^2 + \lambda \|w\|_1 &\rightarrow \min_w \Leftrightarrow \sum_{i=1}^m (y_i - a(x_i, w))^2 + \lambda \sum_{j=1}^n |w_j| \rightarrow \min_w \Leftrightarrow MSE + L1\text{-регуляризатор} \rightarrow \min_w, \\ L2: \|Xw - y\|_2^2 + \lambda \|w\|_2^2 &\rightarrow \min_w \Leftrightarrow \sum_{i=1}^m (y_i - a(x_i, w))^2 + \lambda \sum_{j=1}^n w_j^2 \rightarrow \min_w \Leftrightarrow MSE + L2\text{-регуляризатор} \rightarrow \min_w \end{aligned}$$

Коэффициент регуляризации
(shrinkage penalty)

$\lambda = 0$ – получаем классическое решение

$\lambda \rightarrow +\infty$ – меньше «затачиваемся на данные»
и больше регуляризуем

Перед регуляризацией –
стандартизация!!!

Вероятностный смысл суммы в Loss-функции

$$Loss = MSE + L2 = \frac{1}{2m} \sum_i (y_i - a(x_i, w))^2 + \lambda \|w\|^2 = \frac{1}{2m} \sum_i Err_i^2 + \lambda \|w\|^2.$$

$$P(w | Err) = \{ \text{теорема Байеса} \} = \frac{P(Err | w) P(w)}{P(Err) |_{\forall w}} \rightarrow \max,$$

$P(Err | w)$ – функция правдоподобия, $P(Err) |_{\forall w} := 1$ (найдётся такой вектор w ...)

$$P(w | Err) = \left\{ \begin{array}{l} \text{независимость невязок,} \\ Err \sim N(0, \sigma^2), w \sim N(0, \sigma_w^2) \end{array} \right\} = \prod_i \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{Err_i^2}{2\sigma^2}} \prod_j \frac{1}{\sqrt{2\pi\sigma_w^2}} e^{-\frac{w_j^2}{2\sigma_w^2}} \Rightarrow$$

$$-\ln P(w | Err) = \alpha \sum_i Err_i^2 + \lambda \sum_j w_j^2 \Rightarrow MSE + L2 \rightarrow \min_w$$

Т.е., чтобы держать веса поближе к нулю, предполагая нормальное распределение весов с нулевым матожиданием, следует минимизировать такую сумму: $MSE + L2$.

Другие варианты составной Loss-функции


Случай нескольких таргетов в одной задаче: $Loss = \alpha_1 MSE(C_{меди}) + \alpha_2 MSE(C_{никеля})$

Случай нескольких таргетов в одной задаче:
Loss = Sum of Localization Losses (Multiple Objects)

Случай одного лосс для 2-х задач:
Loss = Classification Loss + Localization Loss



Случай «штрафов»:
Loss = MSE + «штраф за сложность»
(приоритет простым, «коротким» моделям),
Loss = Classification Loss + «штраф за границу»
(регуляризатор делимости объектов)



Спасибо за внимание!
Вступайте в группу по дисциплине!



Запорожцев Иван Федорович
zaporozhtsev.if.work@gmail.com