

Методы оптимизации

ИТМО, 2 курс, 4 семестр

Лекция №6

Методы глобальной оптимизации

Запорожцев Иван Федорович
zaporozhtsev.if.work@gmail.com

Методы глобальной оптимизации

Имеют элементы случайного выбора в процессе решения, что позволяет решить проблемы «застревания» в локальных минимумах (сочетают **достоинства математического анализа и дискретной математики**).

В общем случае требуют большого количества итераций.

Применяются для решения задач с дискретной областью определения.

Удобны при решении комбинаторных задач (найти оптимальную перестановку, разбиение, размещение, сочетание и т.д.).

Метод имитации отжига (simulated annealing)

Отжиг металла – технологический процесс, заключающийся в нагревании и постепенном охлаждении металла для увеличения его однородности, восстановления кристаллической структуры с целью упрощения обработки

Рассмотрим на примере задачи коммивояжёра:

Есть n городов, соединённых между собой дорогами. Необходимо проложить между ними кратчайший замкнутый маршрут, проходящий через каждый город только один раз.

Будем минимизировать функцию $f(x)$ от состояния x . В данном случае x – это перестановка вершин (городов) в том порядке, в котором будем их посещать, а $f(x)$ есть длина соответствующего пути. Возьмём в качестве начального решения произвольное состояние – в данном случае случайную перестановку.

Метод имитации отжига (simulated annealing)

Введём *температуру* t — какое-то действительное число, изначально равное единице, которое будет изменяться в течение оптимизации и влиять на вероятность перейти в соседнее состояние.

Пока не сработает критерий останова, будем повторять следующие шаги:

1. Уменьшим температуру $t_k = T(t_{k-1})$.
2. Выберем случайного *соседа* x : какое-то состояние y , которое может быть получено из x каким-то небольшим изменением.
3. С вероятностью $p(f(x), f(y), t_k)$ сделаем присвоение $x := y$, иначе оставим x , как есть. Например, $p = \exp(-(f(y) - f(x)) / t_k)$.

Метод имитации отжига (simulated annealing)

Эвристики:

1. В начале оптимизации решение и так плохое, и можем позволить себе высокую температуру и риск перейти в состояние хуже. В конце наоборот — решение почти оптимальное, и не хотим терять прогресс. Температура должна быть высокой в начале и медленно уменьшаться к концу.

2. Алгоритм будет работать лучше, если функция $f(x)$ гладкая.

3. Вероятность смены состояния должна быть меньше, если новое состояние хуже, чем старое. Также вероятность должна быть больше при высокой температуре. Например, $p = \exp(-(f(y) - f(x)) / t_k)$.

Метод имитации отжига (simulated annealing)

В задаче коммивояжера:

1. $t_k = \gamma \cdot t_{k-1}$, где γ это какое-то число, близкое к единице (например, 0.99). Оно должно зависеть от планируемого количества итераций: оптимизация при низкой температуре почти ничего не будет менять.
2. В случае с перестановками этим минимальным изменением может быть, например, своп двух случайных элементов.
3. Если y не хуже, то есть $f(y) \leq f(x)$, то переходим в него в любом случае. Иначе делаем переход в y , с вероятностью $p = e^{\frac{f(x)-f(y)}{t_k}}$ — это экспонента отрицательного числа, и она даст вероятность в промежутке $(0, 1)$.

Метод имитации отжига (simulated annealing)

Дана шахматная доска $n \times n$ и n ферзей.

Нужно расставить их так, чтобы они не били друг друга.

Будем кодировать состояние x так же перестановкой чисел от 0 до $(n-1)$: ферзь номер i будет стоять на пересечении i -той строки и $p(i)$ -того столбца.

Такое представление кодирует не все возможные расстановки: не учтутся те расстановки, где ферзи бьют друг друга по вертикали или горизонтали.

Тогда целевая функция $f(x)$ – число ферзей, которые не бьют друг друга

Генетический алгоритм. Идеи

Вектор очередного приближения рассматривается как Хромосома.
Компоненты хромосомы – Гены (ген – аналог переменной/признака).
Целевая функция определена на хромосомах.
Причём на каждой итерации «активное» приближение не одно: есть Популяция (совокупность хромосом).

Итерационный процесс сводится к обновлению хромосом:

- 1) детерминированная часть: пара хромосом обмениваются генами (обмен значениями в выбранных компонентах) – Скращивание (=кроссинговер, crossover);
- 2) элемент случайности: произвольно выбранные гены после скрещивания изменяют своё значение – Мутации.

Состав хромосом меняется: «выживают» те гены (и те хромосомы), которые на итерации ближе к оптимуму целевой функции.

Метод муравьиной колонии (ACO – Ant Colony Optimization)

Введение: поиск методом роёв [Swarm – рой]

Идея: решение сложных комбинаторных задач методом роёв (пчёл) или колоний (муравьёв) заключается в использовании большого числа **активных агентов**, каждый из которых выполняет **простые действия**, по исследованию пространства решений и нахождению оптимальных путей в нём, при этом в совокупности благодаря **кооперации**, они **решают сложную задачу**.

Один из самых популярных методов роёв – «колония муравьёв». Агенты-«муравьи» кооперируются друг с другом, обмениваясь информацией при помощи «феромонов». Каждый агент итеративно выбирает следующий шаг, используя набор эвристик и информацию с предыдущего шага. Из-за итеративной и параллельной природы метода, он способен осуществлять поиск по пространству большой размерности и формировать решение, близкое к оптимальному.

Метод муравьиной колонии (ACO – Ant Colony Optimization)

Принцип работы заключается в моделировании способности муравьёв быстро находить кратчайший путь от муравейника к источнику пищи.

При движении муравей оставляет след из феромонов, который распознают другие муравьи при выборе своего пути.

Чем больше муравьёв следует по одному пути, тем сильнее на этом пути феромонный след, однако, со временем, если след не обновлялся, он может испариться.

В естественной среде это поведение позволяет муравьям находить новый путь, если старый оказывается недоступен.

Метод муравьиной колонии (ACO – Ant Colony Optimization)

В общем случае, проблема формулируется в терминах взвешенного графа, где вес может выражать длину пути между вершинами, либо некоторую иную стоимость добавления вершины в пройденный путь при нахождении в другой вершине графа.

Дополнительно каждое ребро имеет переменное значение феромона -- отражает частоту выбора перехода муравьями.

Метод муравьиной колонии vs Генетический алгоритм

- Поиск решения осуществляется **популяцией активных агентов**, стартующих поиск из разных точек, что обеспечивает эффективное покрытие пространства решений. *Для генетических алгоритмов мы также оперируем популяцией генов, т.е. множеством стартовых точек. Поиск новых решения осуществляется при помощи оператора мутации гена (mutation). Муравьи путешествуют, гены мутируют.*
- **Агенты обмениваются информацией**, оставляя феромон, в процессе поиска в перспективных точках пространства. *Для генетических алгоритмов обмен информацией осуществляется операцией скрещивания (crossover) пары или большего числа генов. Муравьи с большей вероятностью идут туда, где много феромона, гены чаще оставляют потомство от скрещивания с перспективными генами.*
- **Возможности распараллеливания** процесса поиска по агентам. *Аналогично для генетических алгоритмов.*

Метод муравьиной колонии vs Генетический алгоритм

- ACO можно интерпретировать как вариант **обучения с подкреплением** (Reinforcement Learning), т.е. лучшие решения получают большее подкрепление (больше феромонов и, соответственно, больше вероятность выбора этого пути поиска другим агентом на следующей итерации). *В случае генетических алгоритмов подкрепление осуществляется оператором селекции (selection) и элитизма – в следующее поколение попадают более «приспособленные» гены.*
- **Распределённая долгосрочная память** – сохраняется информация о результатах прошлых поисков. *Генетические алгоритмы являются, напротив, «марковскими» в том смысле, что вероятность следующего состояния зависит только от текущего и не зависит от предыдущих.*
- **Эффективный поиск** по всему пространству решений, который обеспечивается стохастической природой алгоритма. Можно комбинировать с локальными оптимизационными алгоритмами (глобальный алгоритм находит перспективный сегмент пространства решений, а дальше запускает процесс локальной оптимизации, находящий лучшее решение в этом сегменте эффективным локальным алгоритмом).

Метод муравьиной колонии для отбора признаков (UFSACO)

Unsupervised Feature Selection Method Based on Ant Colony Optimization

Перед началом процесса отбора признаков, пространство поиска представляется как полностью связанный ненаправленный граф $G = \langle F, E \rangle$, где множество узлов в графе представляет собой первоначальное множество признаков $F = \{F_1, \dots, F_n\}$, а множество рёбер графа $E = \{(F_i, F_j) | F_i, F_j \in F\}$ представляет собой множество всех пар узлов. Вес каждого ребра $(F_i, F_j) \in E$ соответствует мере «похожести» между признаками F_i и F_j . Такой мерой похожести может быть косинусная мера:

$$\text{sim}(A, B) := \left| \frac{\sum_{i=1}^N a_i b_i}{\sqrt{\sum_{i=1}^N a_i^2 \sum_{i=1}^N b_i^2}} \right| \in [0, 1], \text{ где } a_i \text{ и } b_i - \text{значения признаков } A \text{ и } B \text{ на } i\text{-ой}$$

записи.

Мы определяем понятия «**эвристическая информация**» и «**степень привлекательности**». В базовой реализации алгоритма

- «Эвристическая информация» $\eta(F_i, F_u)$ – обратное значение от степени похожести между признаками. Чем меньше похожесть – тем больше информация.
- «Степень привлекательности» узла τ_i – соответствует количеству «феромона», оставленного и не успевшего испариться в этом узле. Она обновляется итеративно на каждом шаге алгоритма.

Метод муравьиной колонии для отбора признаков (UFSACO)

Unsupervised Feature Selection Method Based on Ant Colony Optimization

1. На первой итерации «степени привлекательности» (количеству феромона) каждого узла присваивается одинаковое значение $c \in (0,1)$.
2. На каждой итерации случайное число агентов («муравьёв») помещается на каждый узел, вероятность размещения агентов по узлам пропорциональна их степени привлекательности (количеству феромона).

3. Каждый агент осуществляет переход по графу согласно вероятностному правилу перехода, который основывается на комбинации «эвристической информации» между узлами и количеством «феромона» на сопряжённых узлах следующим образом:
Пусть $q_0 \in [0,1]$ – константа, а $q \in [0,1]$ – случайное равномерно распределённое число. Если $q \leq q_0$ тогда осуществляется шаг **exploitation** (применения текущей оптимальной стратегии), в противном случае, осуществляется шаг **exploration** (исследование пространства). Шаг exploitation осуществляется с вероятностью q_0 , а exploration – с вероятностью $1 - q_0$.

Чередование шагов исследования и применения аналогично подходу в обучении с подкреплением.

Оба шага обеспечивают поиск неисследованные данным агентом узлы с **максимальным количеством феромона** и **наименее похожие** на уже выбранные узлы.

Метод муравьиной колонии для отбора признаков (UFSACO)

Unsupervised Feature Selection Method Based on Ant Colony Optimization

Шаг исследования (exploration), стохастический переход:

если k -ый агент находится на i -ом признаке, то этот агент переходит на j -ый признак с вероятностью:

$$P_k(i, j) = \begin{cases} \frac{[\tau_j][\eta(F_i, F_j)]^\beta}{\sum_{u \in J_i^k} [\tau_u][\eta(F_i, F_u)]^\beta}, & \text{если } j \in J_i^k \text{ и } q > q_0, \\ 0, & \text{в других случаях} \end{cases}, \text{ где}$$

τ_u – желательность (количество феромона) в u -ом узле [вероятность перехода пропорциональна желательности целевого узла]

$\eta(F_i, F_u)$ – эвристическая информация между i -ым и u -ым узлом (обратное значение степени сходства между ними $1/\text{sim}(F_i, F_u)$) [вероятность перехода обратно пропорциональна степени схожести целевого и исходного узла]

J_i^k – набор признаков (узлов), которые k -ый агент, находящийся в i -ом узле ещё не посещал.

β – параметр > 0 , управляющий важностью схожести признаков по сравнению с желательностью.

Т.е. шаг исследования: переход в ранее неисследованный узел происходит с вероятностью, пропорциональной количеству феромона нового узла и обратно пропорциональной степени близости между старым и новым узлами.

Шаг применения exploitation, жадный поиск: если k -ый агент находится на i -ом признаке, то этот агент переходит на j -ый признак, который вычисляется формулой:

$$j = \underset{u \in J_i^k}{\operatorname{argmax}} [\tau_u][\eta(F_i, F_u)]^\beta, \text{ если } q \leq q_0$$

Т.е. шаг применения: переход в узел происходит с максимальным количеством феромона нового узла, делённую на степень близости между старым и новым узлами.

Метод муравьиной колонии для отбора признаков (UFSACO)

Unsupervised Feature Selection Method Based on Ant Colony Optimization

4. Число раз, когда i -ый признак был отобран каким-либо агентом сохраняется в массиве Feature Count – FC_i .
5. После завершения итерации количество феромона для каждого узла обновляется правилом обновления:

Количество феромона узла обновляется на основании значения его feature count (чем больше раз признак был выбран, тем больше феромона ему присваивается) и с учётом коэффициента испарения уже ранее присвоенного феромона ρ :

$$\tau_i(t + 1) := (1 - \rho)\tau_i(t) + \frac{FC(i)}{\sum_{j=1}^n FC(j)}$$

Количество феромона на i -ом узле после $t+1$ итерации равно количеству феромона на том же узле в прошлой итерации плюс доля посещений данного узла в сумме всех посещений (выборки всех признаков).

6. Алгоритм останавливается если достигнут критерий остановки, например, число итераций или минимальное число узлов, которые должны быть посещены каждым агентом. Алгоритм возвращает top m узлов с максимальным количеством феромона. Else goto 2.

Спасибо за внимание!

Запорожцев Иван Федорович
zaporozhtsev.if.work@gmail.com